

DOI:10.13196/j.cims.2023.0532

融合生成对抗网络和难例挖掘的 产品质量预测模型

李剑锋¹, 柏雪¹, 赵春财², 钱朋超², 王洪涛¹, 徐伟风³

(1.中国计量大学 经济与管理学院,浙江 杭州 310018;

2.新凤鸣集团研究院质量管理部,浙江 桐乡 314513;

3.杭州古珀医疗科技有限公司 研发中心,浙江 杭州 311200)

摘要:针对连续性工业生产特点,重点关注类别不平衡造成的不合格样本召回率低问题。为了从高维数据提取有效特征,结合 one class F-score 和最小冗余最大相关性在特征提取方面的优势,有效降低特征维度并提取有价值特征;利用 Wasserstein 生成对抗网络(WGAN)方法扩增不合格样本数量;通过类别权重优化 Focal Loss 函数以提高困难样本识别率;通过轻量级梯度提升机算法结合阈值移动策略,构建基于 WGAN 数据增强和难例挖掘技术的质量预测模型(WGAN_Focal Loss_LGB(TM))。将所提模型应用于开源 SECOM 数据集,验证了所提方法的有效性。

关键词:高维数据;Wasserstein 生成式对抗网络;Focal Loss 函数;难例挖掘;轻量级梯度提升机算法;阈值移动;产品质量预测

中图分类号:TP18

文献标识码:A

Product quality prediction model based on generative adversarial network and hard case mining

LI Jianfeng¹, BAI Xue¹, ZHAO Chuncai², QIAN Pengchao², WANG Hongtao¹, XU Weifeng³

(1. School of Economics and Management, China Jiliang University, Hangzhou 310018, China;

2. Department of Quality Management, Xinfengming Group Research Institute, Tongxiang 314513, China;

3. Research and Development Center, Hangzhou GUPO Technology, Hangzhou 311200, China)

Abstract: According to the characteristics of process industries, the issue of low recall in identifying defective products caused by imbalanced class was addressed. To extract effective features from high-dimensional data, the advantages of one class F-score and mRMR in feature extraction were combined to effectively reduce the feature dimension and extract valuable features. Then, the Wasserstein Generative Adversarial Network (WGAN) algorithm was employed to augment the quantity of defective product. Subsequently, the focal loss function was optimized with class weights to enhance the recognition rate of hard case. Furthermore, leveraging the LightGBM algorithm in conjunction with a threshold movement strategy, a quality prediction model was constructed based on WGAN and hard case mining techniques. Finally, the proposed model was applied to the open-source SECOM dataset, and the result indicated that the presented approach effectively enhanced the recall rate of defective products while maintaining overall accuracy, which provided a scientific and practical method for in-depth exploration of the intricate mapping relationship between critical production factors and product quality, as well as facilitating intelligent quality prediction efforts.

Keywords: high-dimensional data; Wasserstein generative adversarial network; Focal Loss function; hard case mining; LightGBM algorithm; threshold moving; product quality prediction

收稿日期:2023-08-30;修订日期:2023-10-02。Received 30 Aug. 2023;accepted 02 Oct. 2023.

基金项目:国家自然科学基金面上资助项目(71972172);国家自然科学基金青年基金资助项目(42001201)。Foundation items: Project supported by the National Natural Science Foundation, China(No. 71972172,42001201).

0 引言

随着工业发展及人们对产品质量需求的提高,企业质量管理模式在改变,企业对产品质量的控制不只依赖于操作者经验,而是纷纷转向对制造过程的监控和分析。在日常生产中,如果某项监测指标发生异常,生产人员会凭借经验调整相关参数,以使生产恢复正常。然而由于生产的各个环节紧密相连,一道生产工序发生异常就可能使生产工艺与标准工艺之间出现偏差,并随生产各环节的传递累积,导致产品最终为不合格,此时如果根据监测数据进行事后分析就会明显滞后于生产,而且考虑到生产过程中各变量之间的耦合性,生产监测设备在捕捉到监测变量的异常状态之前,产品质量可能已经出现巨大波动。因此,若能预知产品质量,生产人员就可以提前准备相应的改进工作。

另外,随着现代流程工业生产过程的规模和功能复杂性的迅速增加,可监测的数据指标成倍增长,各种对象和过程之间紧密联系,普遍存在多回路、多尺度耦合现象^[1]。由于生产常具有高维、非平衡、非稳定和强非线性等特点,越发凸显了人工智能技术在挖掘工业数据中的价值^[2]。

利用人工智能技术对产品质量进行预测,即基于生产历史数据建立智能预测模型预测产品质量波动的趋势。通过质量预测模型,企业可以监控与预警生产过程,帮助生产人员及时发现并纠正影响产品质量的异常因素,从而降低生产成本,提升产品质量水平。目前,国内外学者对连续工业生产中的质量预测问题进行了较为广泛的研究,一方面,较多学者将机器学习中的各种基础性分类、回归算法应用于产品质量类别和质量特性预测研究,并针对实际应用场景对算法进行优化与改进;另一方面,基于大量基学习器的集成学习算法预测模型的研究也越来越广泛。VUNDAVILLI 等^[3]采用神经网络算法对纺纱过程进行建模,并利用反向传播算法、遗传算法和蜜蜂算法对神经网络参数进行优化,最终得出优化后的神经网络算法对纱线质量的预测性能最佳;易正明等^[4]提出一种基于过程参数控制的带动量项和变学习率的 BP(back propagation)神经网络算法,结果表明该模型对烧结矿质量的预报命中率达 81.25%;纪英俊等^[5]利用随机森林算法对热轧带钢生产实际数据进行分析,并得出将分类回归树(Classification and Regression Tree, CART)与 C4.5 结合作为子树比单一算法可以提升产品质量

的预测准确率;YE 等^[6]提出一种对不同类别样本实施不同权重的随机森林质量预测方法,并利用连续铸造过程中的实时监测参数对铸造方坯质量进行预测。随着人工智能前沿算法的不断涌现及工业生产大数据模式下的实际需求,一些学者开始将深度学习算法应用于连续性工业产品质量预测研究。BAI 等^[7]利用粗糙集理论选取不同生产阶段的重要参数,构建了基于粗糙知识的自适应提升联合长短期记忆(Adaptive Boosting—Long Short Term Memory, AdaBoost-LSTM)算法制造质量预测模型;刘立邦等^[8]对原始鲸鱼优化算法(Whale Optimization Algorithm, WOA)添加自适应惯性权重与最佳扰动,构建了基于适应全局搜索改进的鲸鱼优化联合长短期记忆算法(Whale Optimization Algorithm—Long Short Term Memory, WOA-LSTM)焦炭质量预测模型,并通过实验证明其精度与运行速度相比对比算法均有提升。

另外,考虑到实际生产中不合格产品数量显著低于合格产品,针对这种不平衡工业生产数据的质量预测,国内外学者也进行了大量研究,主要集中在数据层和算法层。数据层的解决方法以数据处理为核心,在处理后的数据集上构建质量预测模型,进行产品质量的智能预测。数据处理算法可细分为过采样、欠采样以及在二者基础上的拓展与组合。MARTIN-DIAZ 等^[9]研究了不平衡小样本数据中的故障检测问题,将合成少数类过采样技术(Synthetic Minority Over-Sampling Technique, SMOTE)和自适应提升(Adaptive Boosting, Adaboost)算法结合,对 5 种不同类型的故障类型进行检测;阴爱英等^[10]将欠采样和过采样结合对数据进行预处理,并结合支持向量机(Support Vector Machine, SVM)等分类算法对光学薄膜产品进行质量预测;BUSTILLO 等^[11]针对汽车生产中的刀具破损检测问题,将欠采样、过采样和混合采样 3 种数据处理技术与不同算法结合,得出混合采样处理效果更优的结论。在算法层,国内外学者的研究主要集中在 3 个方面:①利用代价敏感函数使少数类样本在算法训练过程中得到更大关注,具体方式为对少数类和多数类样本的分类错误给予不同的惩罚;②采用集成学习整合多个模型,集聚各方优势,减少不平衡数据的影响;③将问题着眼于评判指标,不再使用准确率等常用分类评价指标,而采用更综合的评价指标,或在原有指标基础上进行改进来评价分类效果。董勋等^[12]提出一种代价敏感卷积神经网络方法进行故障检测研究,相比传统的卷积神经网络,该方法的故障样本识别率提

升 22% 以上;吴增源等^[13]研究了家电产品的质检问题,将代价敏感因子引入 AdaBoost-DT 模型,提高了产品质检的稳定性;马立玲等^[14]提出一种针对不平衡数据的 SVM 改进算法,并设置惩罚因子和利用马氏距离优化模糊隶属度,对类间样本和类内样本赋予不同权重,实现了对车辆的故障预警和性能分析;GARRIDO 等^[15]提出一种基于旋转森林的集成方法识别不同的机器运作状态和模型,其性能相比 AdaBoost、随机森林和 SVM 等基础算法更加卓越;周霄晗^[16]研究了一种基于生成式对抗网络(Generative Adversarial Network, GAN)的集成模型,使各 GAN 在各训练子集的分类性能彼此互补;张忠林等^[17]将阈值移动技术融入 Bagging 集成算法,利用校准的后验概率在预测阶段得到对不平衡数据分类的最大化性能测量;胡梦园等^[18]提出基于改进的类权自适应、软投票与阈值移动的集成模型,有效处理了软件缺陷中的这种类别不平衡问题;ESCOBAR 等^[19]针对高度不平衡数据的二分类问题提出新的模型选择准则,在预测、拟合和复杂度 3 个维度上对模型性能进行评价。

综上所述,在现有的利用数据采样技术解决工业数据不平衡问题研究中,基本是在模型构建之前对不同类别数据进行平衡处理,并未考虑该方法对原始数据分布的影响,以及由此造成的重要样本信息丢失和模型过拟合问题^[20]。基于此,本文引入 Wasserstein 生成对抗网络(Wasserstein Generative Adversarial Network, WGAN)技术学习少数类样本的真实分布形态,进而扩增少数类样本数量来降低不平衡程度。另外,简单地平衡不同类别样本数量间的差异或采用代价敏感的方式为不同类别样本分配不同权重,也很难有效解决少数类样本的识别率。本文通过不同类别权重优化 Focal loss 损失函数,以提高困难样本及少数类样本的识别率。

另外,考虑到现在工业生产监测数据通常具有高维特点,本文通过融合 one class F-score 和最小冗余最大相关性(minimum Redundancy Maximum Relevance, mRMR)方法在特征选择上的优势,在保证提取有效特征的同时,较大程度降低特征维度,进而提高模型的响应速度;然后,通过轻量级梯度提升机(Light Gradient Boosting Machine, LightGBM)算法结合阈值移动策略,构建基于 WGAN 数据增强和难例挖掘技术的质量预测模型(WGAN_Focal Loss_LGB(TM));最后,将该模型应用于开源的半导体制造业(Semi-Conductor Manufacturing, SEC-OM)数据集表明,本文所提方法在保证整体准确率的前提下有效提升了不合格样本召回率。

1 基于 WGAN 和难例挖掘的产品质量预测模型

本文从数据集、特征选择和损失函数 3 个维度优化高维不平衡工业产品质量预测问题,构建基于 WGAN 和难例挖掘的产品质量预测模型,整体流程如图 1 所示。特别地,为了处理高维不平衡数据的预测问题,本文首先通过融合 one class F-score 和 mRMR 方法在特征选择方面的优势,保证有效提取特征的同时较大程度地降低特征维度,进而提高模型响应速度,具体流程如图 1 中“1.数据预处理及特征提取”部分所示;接着,引入 WGAN 模型进行少数类样本扩增,以在学习少数类样本分布的前提下扩增少数类样本数量,用于降低数据的不平衡程度,具体流程如图 1 中“2.少数类样本数据增强”部分所示;然后,采用基于 Focal Loss 的难例挖掘技术对 LightGBM 进行优化,并结合阈值移动方法调整 LightGBM 的决策边界,以提高模型的整体性能,具体如流程图 1 中“3.构建难例挖掘模型”部分所示;最后,基于训练过的难例挖掘模型进行预测。




图1 基于WGAN数据增强和难例挖掘技术的质量预测流程

1.1 数据集来源及处理

本文采用加州大学欧文分校 (University of California Irvine, UCI) 机器学习数据库中的 SECOM^[21] 数据集进行不平衡工业数据预测研究。SECOM 数据集是从半导体晶圆制造生产线上收集的 2008.01.08~2008.12.10 期间的监测数据,共 1 567 例样本,每一例样本由 591 项传感器监测指标及对应的质量标签组成。其中,各样本的传感器指标均存在不同程度的缺失;标签“−1”表示合格样本,“1”表示不合格样本。经统计,该数据集有 1 463 例合格样本,104 例不合格样本,是典型的高维不平衡制造数据集。

在数据处理方面,首先剔除数据集中的零方差监测指标与缺失值比例超 40% 的监测指标;然后对缺失值比例在 40% 以下的监测指标采用 K 最邻近 (K -NearestNeighbor, KNN) 算法填充缺失值;最后采用孤立森林算法检测异常样本,剔除 31 例异常样本;最终获得 1 432 例样本且每例样本由 436 个特征构成,其中 1 328 例合格样本,104 样本不合格样本。

1.2 关键质量特性的提取

为了处理高维特征的 SECOM 数据,本文提出一种融合 one class F-score 和 mRMR 的特征选择方法。one class F-score 用 F-score 作为特征选择的标准,即特征的 F-score 越高,该特征对分类器性能提升得越大,也就越重要,进而进行特征筛选。mRMR 则通过计算特征之间以及特征与目标变量间的互信息进行特征选择,最终选择出的特征相互之间冗余度低且与目标变量高度相关。

本文采用 one class F-score 特征选择方法在处理不平衡数据上的优势,并针对其不能有效衡量特征间互信息的缺点,用 mRMR 准则对其进行优化,最终计算每一项质量特性的错误匹配率 (FMR) 得分,用于衡量特性的重要程度。具体地,按照式(1)对质量特性的 F-score 和 mRMR 得分进行融合,计算得到每项质量特性的 FMR 重要性得分。

$$FMR(i) = 10 \times F(i) \times (1 + 10 \times m(i)). \quad (1)$$
式中: i 为特征序号; $F(i)$ 为 one class F-score 方法第 i 个特征的得分; $m(i)$ 为 mRMR 方法第 i 个特征的得分。

为了尽可能多地从原始数据中提取关键质量识别特征,并验证关键质量特性的错误匹配率重要性得分的稳定性能,本文在原始数据上进行 10 折交叉

验证,每次将 70% 的数据作为训练集,构建 LightGBM 模型进行训练,剩下 30% 的数据作为预测集,采用 LightGBM 模型输出关键质量特征识别结果。

另外,为了避免划分数据的随机性对识别结果的影响,引入集成学习中的 Majority Voting 组合策略思想得出最终结果。具体地,合并统计 10 折交叉验证中每次提取的特征,将出现次数过半(即大于等于 5)的特征纳入最终确定的关键质量特性集合中。SECOM 制造数据提取出的 12 项关键质量特征如表 1 所示。

表 1 SECOM 制造数据的关键质量特征

特征	各集合出现的频次
No. 140	7
No. 275	6
No. 585	5
No. 540	5
No. 524	5
No. 470	5
No. 448	5
No. 366	5
No. 324	5
No. 207	5
No. 155	5
No. 122	5

1.3 基于 WGAN 的不合格样本数据增强

针对 SECOM 中不合格样本的数据占比较低导致的不平衡问题,本文采用 WGAN^[22] 算法对不合格样本数据进行数据增强。WGAN 是生成对抗网络^[23] GAN 中具有代表性的改进模型,GAN 是由 GOODFELLOW 于 2014 年基于零和博弈思想提出的一种神经网络模型,主要由生成器网络(generator network)和判别器网络(discriminator network)组成。生成器网络可以视为数据生成模型,通过学习样本的分布规律将输入的随机噪声转变为新的数据样本;判别器网络则充当分类模型角色,对样本来自于真实数据集还是生成数据集进行判断。然而 GAN 模型在实际训练过程中,通常会出现生成器梯度消失和模式坍塌两方面问题^[24],因此 WGAN 提出用 Wasserstein 距离代替 JS 散度(Jensen-Shannon divergence),有效缓解了模式坍塌问题。

在本例中,生成器网络用来拟合不合格样本的真实数据,生成新的样本数据;判别器网络用来判断

所输入的样本数据属于真实的不合格样本数据还是生成的不合格样本数据。当 WGAN 训练直至收敛时,将生成的数据添加进原始制造数据中,形成相对平衡的样本数据,用于构建产品质量预测模型。

为了找到增强效果较优的不合格样本的生成样本,本文通过对比原始不合格样本与 WGAN 所生成样本各监测指标的边际分布图,选择相对较优的增强数据集作为最终不合格样本的样本数据集。

具体地,本文构建多组网络参数下的 WGAN 数据生成模型,然后将 104 例不合格样本作为 WGAN 模型的输入,在不同参数的 WGAN 模型下输出多组不合格样本的增强数据集。为了选择一组相对较优的模型参数,本文将 WGAN 生成的增强

样本数据分别与原始负样本数据进行对比,通过对比生成数据与原始数据间各质量特征边际分布图的相似程度,选择相似程度高且相似特征数量多的生成数据作为最终的增强数据集。图 2 所示为 WGAN 模型对产品质量中 No. 122 和 No. 140 两组关键特征的边际分布对比图,可见在参数组合 1 下, WGAN 生成的 No. 122 和 No. 140 的边际分布与原始数据边际分布相似,剩余 10 组关键质量特征的边际分布图在参数组合 1 下有较为明显的优势。因此,选择参数组合 1 作为最终的 WGAN 参数,具体为:优化器为 RMSprop,学习率为 0.000 05,生成器激活函数为 *tanh*,判别器激活函数为 *sigmoid*,迭代次数为 5。




图2 WGAN数据增强效果对比

1.4 基于优化的 Focal Loss 与阈值移动的 LightG-BM 模型

在不平衡数据中,根据分类器划分样本时的难易程度分为易分样本和难分样本。由于难分和易分样本也普遍存在不平衡现象,分类器没有充分的把握对类别进行判别,导致输出值处于决策阈值附近^[25]。

本文合格样本与不合格样本分布曲线存在较大面积的重合区域,导致一般的分类模型很难准确划分这两类样本,具体表现为输出的预测标签处于决策阈值附近。因此,不仅要注重少数类样本的错分代价,还要关注训练过程中判断为难分样本的不合格样本。

对于少数类样本的错分代价,已有研究提出在

原始交叉熵损失函数上引入权重 $\alpha \in (0, 1)$, 增加少数类样本对模型训练损失的贡献程度, 形成加权交叉熵损失函数^[26], 即

$$L(\hat{y}_i, y_i) = - \sum_{i=1}^N [\alpha y_i \log(\hat{y}_i) + (1 - \alpha)(1 - y_i) \log(1 - \hat{y}_i)]. \quad (2)$$

然而, 加权交叉熵损失函数只能解决正负样本数量不均衡的问题, 占比较大的易分类样本在模型训练损失增加过程中的主导作用依然存在^[27], 这类样本对模型学习能力的提升作用很弱, 甚至会带来过拟合风险。为此, 本文引入 LIN 等^[28]提出的焦点损失函数 Focal Loss, 其为在原始交叉熵损失函数的基础之上引入聚焦参数 γ , 从而以指数衰减的方式降低大量易分样本在训练过程中所占的权重, 增加难分样本的权重。Focal Loss 损失函数

$$L(\hat{y}_i, y_i) = - \sum_{i=1}^N [y_i (1 - \hat{y}_i)^\gamma \log(\hat{y}_i) + (1 - y_i) \hat{y}_i^\gamma \log(1 - \hat{y}_i)]. \quad (3)$$

式中: $\hat{y}_i^\gamma$ 和 $(1 - \hat{y}_i)^\gamma$ 为调制系数; γ 为聚焦参数, $\gamma \geq 0$ 。

本文结合加权交叉熵损失函数中平衡多数类和少数类样本的概念, 在 Focal Loss 损失函数中加入样本类别权重 α , 使原先的交叉熵损失函数在关注少数类样本的同时, 解决易分样本过多所导致的模型性能降低的问题, 从而提升对不合格样本的识别力度。使用 Focal Loss 优化的交叉熵损失函数表示为

$$L(\hat{y}_i, y_i) = - \sum_{i=1}^N [\alpha y_i (1 - \hat{y}_i)^\gamma \log(\hat{y}_i) + (1 - \alpha)(1 - y_i) \hat{y}_i^\gamma \log(1 - \hat{y}_i)]. \quad (4)$$

为了预测 SECOM 中的样本是否合格, 本文选择微软开源的 LightGBM^[29] 集成学习算法, 并用优化的 Focal Loss 交叉熵损失函数替换 LightGBM 中的原始交叉熵损失函数, 在已进行数据增强处理后的平衡样本数据集上构建难例挖掘的 LightGBM 质量预测模型。另外, 为了进一步提升少数难分样本的识别准确率, 引入阈值移动策略 (Threshold Moving, TM)^[30]。目前, 已有较多学者将阈值移动策略应用于不平衡数据分类问题^[17-18, 31], 通过改变分类器的决策边界来处理不平衡数据。本文在质量预测模型的测试阶段应用阈值移动策略, 具体步骤如下:

步骤 1 在经 WGAN 方法扩增的 SECOM 训

练数据集 $D = \{(x_i, y_i)\}, i = 1, 2, \dots, n, y_i \in \{0, 1\}$ 上, 训练经 Focal Loss 优化的 LightGBM 模型。

步骤 2 给定测试样本 x , 模型将其类别预测为 k 的条件概率为 $P(y = k | x)$, 其中 $k \in \{0, 1\}$, $y = k$, 即样本 x 的后验概率估计值为 $P(y = k | x)$ 。

步骤 3 用样本类别的后验概率估计值除以设定的类别阈值 τ_k , 得到样本 x 在每个类别上的得分 s_k , 以最高得分 s_k 对应的类别 k 作为样本 x 的类别标签。

本文将类别阈值 τ_k 设置为样本数据中的先验概率, 即 $\tau_0 = P(y = 0)$ 。例如, 质量预测模型判断某样本为不合格样本的概率为 0.3, 且该类别在制造数据集集中的先验概率为 0.2, 计算可得该样本在不合格样本类别上的得分为 1.5, 在合格样本类别上的得分为 0.875, 最终该样本在预测阶段的类别标签确定为不合格样本。

2 结果分析与讨论

2.1 评估指标

对于非均衡数据, 简单地使用整体分类准确率无法准确反映分类器在少数类样本中的表现。本文从质量预测的具体需求出发, 选取 3 项指标对质量智能预测模型的效果进行评价, 分别为 AUC、召回率 *Recall* 和几何平均 *G-mean*。另外, 为了详细展示各指标计算方法, 用 *TP* (true positive), *TN* (true negative), *FP* (false positive), *FN* (false negative) 分别表示正例中分类正确和错误、反例中分类正确和错误的数量。

(1) AUC

AUC 衡量了模型在不同阈值下分类的能力, 即真正例率 *TPR* 对假正例率 *FPR* 曲线下的面积^[32], 其值越接近 1, 表示模型的分类性能越好, 即能更好地区分合格样本和不合格样本。*TPR* 和 *FPR* 的计算方法分别为:

$$TPR = \frac{TP}{TP + FN}; \quad (5)$$

$$FPR = \frac{FP}{FP + TN}。 \quad (6)$$

(2) 召回率

召回率 *Recall* 表示模型分类正确的不合格样本数量占全部不合格样本数量的比值, 其值越大, 模型对不合格样本的识别准确率越高。

$$Recall = \frac{TP}{TP + FN}。 \quad (7)$$

(3) 几何平均

几何平均 $G-mean$ 常用于不平衡数据分类问题,其综合考虑了模型的召回率和特异性,能在保证少数类和多数类分类精度平衡的同时,最大化两类的精度^[33]。因此, $G-mean$ 越大,模型在合格样本与不合格样本间平衡的效果越好,该指标综合反映了模型的整体性能。

$$G-mean = \sqrt{\frac{TP}{TP+FN} \times \frac{TN}{FP+TN}} \quad (8)$$

2.2 实验及结果分析

根据图1流程构建本文提出的 WGAN_Focal Loss_LGB(TM)模型,在 SECOM 公开数据集上测试,得到 $AUC = 0.615$, $Recall = 0.931$, $G-mean = 0.528$ 。

为证明本文所提特征选择融合算法、WGAN 数据增强及基于类别权重优化的 Focal Loss 结合阈值移动的难例挖掘技术,在提升产品质量预测集成模型性能方面的优势,设计如下对比实验。

2.2.1 特征选择融合算法实验设计及结果分析

为了验证本文特征融合算法的有效性,选择 Relief (relevant features) 算法和 FAST (features from accelerated segment test) 算法进行对比。图3~图5所示分别为 Relief 算法、FAST 算法和本文所提特征选择融合算法在关键质量特征数量、Recall 和 AUC 3项指标的对比。




图3 10次实验下各方法识别出的关键质量特性个数




图4 10次实验下的Recall评价指标对比




图5 10次实验下的AUC评价指标对比

明显可见,本文特征融合算法在关键质量特征数量识别上具有较强的稳定性,而 Relief 和 FAST 算法在不同数据集上识别出的关键质量特征数量明显不稳定。另外,Relief 和 FAST 算法在 Recall 上也存在明显的劣势。因此,本文所提基于特征选择融合算法的关键质量识别方法在识别稳定性和不合格样本召回率上均具有一定优势,可以应用于具体的关键质量特性实践问题。

2.2.2 WGAN 数据增强、Focal Loss 和移动策略实验设计及结果分析

为证明 WGAN 数据增强的有效性,本文采用 SMOTE^[34], Borderline_SMOTE^[35] (BSMOTE), ADASYN^[36] (adaptive synthetic sampling) 3种流行的数据过采样算法,在 SECOM 数据集上进行对比分析。在此基础上,结合优化的 Focal Loss 和移动平均策略,继续在 SECOM 数据集上进行实验对比,以证明 Focal Loss 和阈值移动策略的有效性。其中,将 SMOTE 采样方法、Focal Loss 及移动平均策略结合 LightGBM 算法的模型记为 SMOTE_FocalLoss_LGB(TM),将 BSMOTE 与 ADASYN 采样方法分别与 Focal Loss 和移动平均策略结合 LightGBM 算法的模型记为 BSMOTE_FocalLoss_LGB(TM),ADASYN_FocalLoss_LGB(TM),将 WGAN 与移动平均策略结合 LightGBM 算法的模型记为 WGAN_LGB(TM),将 WGAN 与 Focal Loss 结合 LightGBM 算法的模型记为 WGAN_FocalLoss_LGB。表2所示为本文方法与上述算法的对比结果。

为了更形象地对比各模型,将表2中的各指标数据可视化如图6所示的柱状图。

表 2 各方法优势对比的实验结果

评价 指标	模型					
	WGAN_	SMOTE_	BSMOTE_	ADASYN_	WGAN_LGB	WGAN_
	Focal Loss_	Focal Loss_	Focal Loss_	Focal Loss_	(TM)	Focal Loss_
	LGB(TM)	LGB(TM)	LGB(TM)	LGB(TM)		LGB
AUC	0.615	0.511	0.516	0.515	0.5	0.554
Recall	0.931	0.862	0.897	0.828	1.0	0.276
G_mean	0.528	0.371	0.348	0.409	0.0	0.479




图6 方法优势对比实验结果柱状图

明显地,相对于广泛使用的 SMOTE,BSMOTE, ADASYN 3 种过采样算法,本文所提 WGAN 数据增强模型在 AUC,Recall,G-mean 3 项指标上都具有明显优势。3 种常见的过采样方法在 G-mean 均较低,表明过采样算法获取的不合格扩充样本并未很好地反映真实数据的原始分布形态,其牺牲了过多的合格样本来提升不合格样本的分类准确率,导致所获取的平衡数据上构建的质量预测模型的泛化能力不足。而本文的 WGAN 数据增强方法能更好地拟合数据真实的分布形态,保证了数据的多样性,因此能够保证整体分类准确率,进而提升不合格样本的分类性能。

优化的 Focal Loss 是否应用于 LighGBM 明显影响各评价指标。未改进原始交叉熵损失函数的 LightGBM 模型的 $G_mean = 0$,与 Recall 结合来看,该模型将所有合格样本预测为不合格样本,导致不合格样本的 $Recall = 1$,综合评价指标 $G_mean = 0$ 。原因是虽然利用 WGAN 数据增强方法使正负样本数量达到平衡,但是仍未解决难分和易分样本不平衡问题,模型在训练过程中会继续优化已经被正确分类的样本,即模型并未充分学习难分样本,无法准确划分易分和难分样本。同时,由于本文的对比模型在测试阶段采用了阈值移动策略,本质上是利用校准的后验概率放宽了对占比较小的不合格样本分类的限制,导致测试集中大量的合格样本被错分为不合格样本,直接表现为不合格样本的分类准

确率极低。由此可以得到,训练阶段如果不考虑产品质量预测中的分类难度问题,只是单纯地在测试阶段降低正类样本的分类阈值,则该模型将不具备难例挖掘的能力,其会过度倾向于少数类样本,导致过量的负类样本被误分为正类,该模型在实际的产品质量预测中会给企业的运营成本带来难以估量的损失。因此,本文将 Focal Loss 难例挖掘技术与移动策略结合,能够使合格产品质量的预测精度处于合理水平之上,在此基础上提升对不合格样本的预测准确率。

阈值移动策略优势对比实验中,在质量预测集成模型的测试阶段不使用阈值移动策略时,不合格样本的分类准确率只有 0.276;使用阈值移动策略而不采用 Focal Loss 进行优化时,样本分类的 AUC 和 G_mean 也不理想,特别是 G_mean 已经降为 0。因此,本文采用阈值移动策略结合 Focal Loss 进行优化的集成学习模型能有效提高质量预测的性能。

综上所述,本文采用 WGAN 数据增强方法在数据层面进行的改进,以及 Focal Loss 损失函数和在实验阶段采用的阈值移动策略,改善了原始集成学习模型在不平衡数据上的预测效果。通过分析发现,各种方法相互补充,既可提高对不合格样本的预测精度,也可保证整体分类准确率高于合理水平,从而兼顾对两类样本的质量预测性能。

3 结束语

针对产品质量特性与质量水平之间映射关系强但影响机理复杂,难以跟踪和优化导致产品质量异常的关键工艺参数,以及由质量数据高维及不均衡造成质量预测准确性较低的问题,本文以集成学习算法为基础,将特征提取、WGAN 数据增强技术与 Focal Loss 难例挖掘技术三种不平衡数据处理方法进行优化,尝试在测试阶段引入阈值移动策略,共同提升不合格样本的预测性能。通过在开源 SECOM

数据集上进行模拟验证,并将本文所提预测模型与已有方法、技术和策略进行优势对比分析表明,相比现有技术,本文所提 WGAN_Focal Loss_LGB(TM)产品质量预测模型能够在数据分布失衡的制造数据集上拥有良好的预测性能,较好地拟合出复杂工序产品制造数据中的非线性关系,同时兼顾不合格样本的召回率与整体产品的预测准确率,对于提高产品质量、降低人工成本、提升企业效益具有重要意义。

未来考虑将模型推广到钢铁制造、石油化工生产等多种类别的连续性生产情景,总结所构建的质量智能预测模型的生产适用性规律,寻找共性,使模型的应用效果更加准确。

参考文献:

- [1] SHANG C, YOU F Q. Data analytics and machine learning for smart process manufacturing: Recent advances and perspectives in the big data era[J]. *Engineering*, 2019, 5(6): 1010-1016.
- [2] CHEN Long, LIU Quanli, WANG Linqing, et al. Data-driven prediction on performance indicators in process industry: A survey[J]. *Acta Automatica Sinica*, 2017, 43(6): 944-954(in Chinese). [陈 龙, 刘全利, 王霖青, 等. 基于数据的流程工业生产过程指标预测方法综述[J]. *自动化学报*, 2017, 43(6): 944-954.]
- [3] VUNDAVILLI P R, KUMAR J P, PRIYATHAM C S, et al. Neural network-based expert system for modeling of tube spinning process[J]. *Neural Computing and Applications*, 2015, 26(6): 1481-1493.
- [4] YI Zhengming, SHAO Huijun. A prediction model for sintering quality based on control of process parameters[J]. *Mining and Metallurgical Engineering*, 2018, 38(6): 92-96(in Chinese). [易正明, 邵慧君. 基于过程参数控制的烧结矿质量预测模型[J]. *矿冶工程*, 2018, 38(6): 92-96.]
- [5] JI Yingjun, YONG Xiaoyue, LIU Yinglin, et al. Random forest based quality analysis and prediction method for hot-rolled strip[J]. *Journal of Northeastern University: Natural Science*, 2019, 40(1): 11-15(in Chinese). [纪英俊, 勇晓玥, 刘英林, 等. 基于随机森林的热轧带钢质量分析与预测方法[J]. *东北大学学报: 自然科学版*, 2019, 40(1): 11-15.]
- [6] YE X M, WU X, GUO Y K. Real-time quality prediction of casting billet based on random forest algorithm[C]//Proceedings of 2018 IEEE International Conference on Progress in Informatics and Computing. Washington, D. C., USA: IEEE, 2018: 140-143.
- [7] BAI Y, SUN Z Z, DENG J, et al. Manufacturing quality prediction using intelligent learning approaches: A comparative study[J]. *Sustainability*, 2018, 10(1): 85.
- [8] LIU Libang, YANG Song, WANG Zhijian, et al. Prediction of coke quality based on improved WOA-LSTM[J]. *CIESC Journal*, 2022, 73(3): 1291-1299(in Chinese). [刘立邦, 杨 颂, 王志坚, 等. 基于改进 WOA-LSTM 的焦炭质量预测[J]. *化工学报*, 2022, 73(3): 1291-1299.]
- [9] MARTIN-DIAZ I, MORINIGO-SOTELO D, DUQUE-PEREZ O, et al. Early fault detection in induction motors using AdaBoost with imbalanced small data and optimized sampling[J]. *IEEE Transactions on Industry Applications*, 2016, 53(3): 3066-3075.
- [10] YIN Aiyang, WU Yunbing, YANG Xiaohua. Hybrid sampling algorithm for manufacturing on imbalance data[J]. *Computer Engineering and Design*, 2018, 39(4): 1053-1058(in Chinese). [阴爱英, 吴运兵, 杨晓花. 面向制造业不平衡数据的混合采样算法[J]. *计算机工程与设计*, 2018, 39(4): 1053-1058.]
- [11] BUSTILLO A, RODRIGUEZ J J. Online breakage detection of multitooth tools using classifier ensembles for imbalanced data[J]. *International Journal of Systems Science*, 2014, 45(12): 2590-2602.
- [12] DONG Xun, GUO Liang, GAO Hongli, et al. Cost sensitive convolutional neural network: A classification method for imbalanced data of mechanical fault[J]. *Chinese Journal of Scientific Instrument*, 2019, 40(12): 205-213 (in Chinese). [董 勋, 郭 亮, 高宏力, 等. 代价敏感卷积神经网络: 一种机械故障数据不平衡分类方法[J]. *仪器仪表学报*, 2019, 40(12): 205-213.]
- [13] WU Zengyuan, ZHOU Caihong, LIU Chang, et al. Home appliance quality inspection based on CS-AdaBoost-DT model with imbalanced big data[J]. *Industrial Engineering and Management*, 2020, 25(5): 42-49(in Chinese). [吴增源, 周彩虹, 刘 畅, 等. 基于不平衡大数据的 CS-AdaBoost-DT 模型在家电产品质检中的应用[J]. *工业工程与管理*, 2020, 25(5): 42-49.]
- [14] MA Liling, GUO Kaijie, WANG Junzheng. A fault diagnosis method of vehicle transmission system based on improved svm[J]. *Transactions of Beijing Institute of Technology*, 2020, 40(8): 856-860(in Chinese). [马立玲, 郭凯杰, 王军政. 基于改进 SVM 的车辆传动系统故障诊断方法[J]. *北京理工大学学报*, 2020, 40(8): 856-860.]
- [15] GARRIDO-LABRADOR J L, PUENTE-GABARRI D, RAMIREZ-SANZ J M, et al. Using ensembles for accurate modelling of manufacturing processes in an IoT data-acquisition solution[J]. *Applied Sciences*, 2020, 10(13): 4606.
- [16] ZHOU Xiaohan. Research on imbalanced data classification based on neural network adversarial and ensembles[D]. Hangzhou: Zhejiang University of Technology, 2019 (in Chinese). [周霄晗. 基于深度神经网络对抗与集成的不平衡数据分类方法研究[D]. 杭州: 浙江工业大学, 2019.]
- [17] ZHANG Zhonglin, WU Dangping. An imbalanced data classification method based on probability threshold bagging[J]. *Computer Engineering & Science*, 2019, 41(6): 1086-1094.

- (in Chinese). [张忠林, 吴挡平. 基于概率阈值 Bagging 算法的不平衡数据分类方法[J]. 计算机工程与科学, 2019, 41(6): 1086-1094.]
- [18] HU Mengyuan, HUANG Hongyun, DING Zuohua. Ensemble model for software defect prediction[J]. Computer Science, 2019, 46(11): 176-180(in Chinese). [胡梦园, 黄鸿云, 丁佐华. 用于软件缺陷预测的集成模型[J]. 计算机科学, 2019, 46(11): 176-180.]
- [19] ESCOBAR C A, MORALES-MENENDEZ R. Process-monitoring-for-quality—A model selection criterion for l_1 -regularized logistic regression[J]. Procedia Manufacturing, 2019, 34: 832-839.
- [20] CHEN Shengling. Research on imbalanced data processing methods for industrial big data[D]. Changsha: National University of Defense Technology, 2018(in Chinese). [陈圣灵. 面向工业大数据的不平衡数据处理方法研究[D]. 长沙: 国防科技大学, 2018.]
- [21] ASUNCION A. UCI machine learning repository[EB/OL]. [2023-09-05]. <http://www.ics.uci.edu/~mlearn/MLRepository.html>.
- [22] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein GAN[EB/OL]. (2017-12-06). [2023-09-05]. <https://arxiv.org/pdf/1701.07875>.
- [23] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[EB/OL]. (2014-06-10)[2023-09-05]. <http://modelai.gettyburg.edu/2020/wgan/Resources/Lesson3/GANs.pdf>.
- [24] WANG Kunfeng, ZUO Wangmeng, TAN Ying, et al. Generative adversarial networks: From generating data to creating intelligence[J]. Acta Automatica Sinica, 2018, 44(5): 769-774(in Chinese). [王坤峰, 左旺孟, 谭 营, 等. 生成式对抗网络: 从生成数据到创造智能[J]. 自动化学报, 2018, 44(5): 769-774.]
- [25] DAI Li. Empirical research on imbalanced classification based on costsensitive[D]. Wuhan: Mathematics and Statistics Central China Normal University, 2020(in Chinese). [代 黎. 基于代价敏感的不平衡分类问题实证研究[D]. 武汉: 华中师范大学, 2020.]
- [26] HO Y, WOOKEY S. The real-world-weight cross-entropy loss function: Modeling the costs of mislabeling[J]. IEEE Access, 2019, 8: 4806-4813.
- [27] ZHOU Zhining, WANG Binjun, ZHAI Yiming, et al. Spam filtering model based on ALBERT dynamic word vector[J]. Netinfo Security, 2020(9): 107-111(in Chinese). [周枝凝, 王斌君, 翟一鸣, 等. 基于 ALBERT 动态词向量的垃圾邮件过滤模型[J]. 信息安全, 2020(9): 107-111.]
- [28] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. Washington, D. C., USA: IEEE, 2017: 2980-2988.
- [29] KE G L, MENG Q, FINLEY T, et al. Lightgbm: A highly efficient gradient boosting decision tree[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. New York, N. Y., USA: ACM, 2017: 3149-3157.
- [30] PROVOST F. Machine learning from imbalanced data sets 101[C]//Proceedings of the AAAI' 2000 Workshop on Imbalanced Data Sets. Menlo Park, Cal., USA: AAAI Press, 2000.
- [31] COLLELL G, PRELEC D, PATIL K R. A simple plug-in bagging ensemble based on threshold-moving for classifying binary and multiclass imbalanced data[J]. Neurocomputing, 2018, 275: 330-340.
- [32] FAWCETT T. An introduction to ROC analysis[J]. Pattern Recognition Letters, 2006, 27(8): 861-874.
- [33] ZHANG Jiawei, GUO Linming, YANG Xiaomei. Improved oversampling and random forest algorithms for imbalanced data[J]. Computer Engineering and Applications, 2020, 56(11): 39-45(in Chinese). [张家伟, 郭林明, 杨晓梅. 针对不平衡数据的过采样和随机森林改进算法[J]. 计算机工程与应用, 2020, 56(11): 39-45.]
- [34] CHAWLA N V, BOWYER K W, HALL L O, et al. Smote: Synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16(1): 321-357.
- [35] HAN H, WANG W Y, MAO B H. Borderline-smote: A new over-sampling method in imbalanced data sets learning[C]//Proceedings of International Conference on Intelligent Computing. Berlin, Germany: Springer-Verlag, 2005: 878-887.
- [36] HE H B, BAI Y, GARCIA E A, et al. Adasyn: Adaptive synthetic sampling approach for imbalanced learning[C]//Proceedings of 2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence). Washington, D. C., USA: IEEE, 2008: 1322-1328.

作者简介:

李剑锋(1977—),男,黑龙江哈尔滨人,副教授,博士,硕士生导师,研究方向:质量智能管理、机器学习,E-mail:ljfwinner@163.com;
 柏 雪(1999—),女,安徽六安人,硕士研究生,研究方向:大数据与人工智能、机器学习、质量管理,E-mail:15156205786@163.com;
 赵春财(1968—),男,江苏高淳人,本科,高级工程师,研究方向:质量管理,E-mail:2894529565@QQ.com;
 钱朋超(1985—),男,河北保定人,本科,工程师,研究方向:质量管理,E-mail:qpc@xfmgroup.com;
 王洪涛(1972—),男,河南商丘人,副教授,博士,硕士生导师,研究方向:质量数字化,E-mail:htwant369@cjlu.edu.cn;
 徐伟风(1991—),男,安徽铜陵人,硕士研究生,研究方向:大数据与人工智能、机器学习、医疗数据挖掘,E-mail:xwfaxx@163.com。