



(12) 发明专利申请

(10) 申请公布号 CN 121327074 A

(43) 申请公布日 2026.01.13

(21) 申请号 202511354935.4

G06F 40/30 (2020.01)

(22) 申请日 2025.09.22

G06F 18/22 (2023.01)

(71) 申请人 芜湖奇瑞信息技术有限公司

地址 241000 安徽省芜湖市经济技术开发区
区长春路8号

申请人 奇瑞汽车股份有限公司

(72) 发明人 陈煜 徐伟风 罗锐 戴闯

(74) 专利代理机构 芜湖安汇知识产权代理有限公司 34107

专利代理师 钟雪

(51) Int.Cl.

G06F 16/3329 (2025.01)

G06N 5/04 (2023.01)

G06N 3/0455 (2023.01)

G06N 3/0895 (2023.01)


权利要求书2页 说明书6页 附图1页

(54) 发明名称

一种MRAG系统的多模态检索增强优化方法

(57) 摘要

本发明提供了一种MRAG系统的多模态检索增强优化方法,MRAG系统采用分阶段训练策略,包括第一阶段的无监督训练及第二阶段有监督训练,其中,第一阶段的将输入的所模态数据的编码特征进行初步对齐,第二阶段的有监督训练进一步引导所有模态数据的编码特征对齐。通过第一阶段的自监督学习可以初始化模型,利用海量的无监督多模态数据,让它获得较为稳健的模态内部表征;第二阶段的基于FGA策略的对比学习更关注模态之间的对齐,并且弥补了模态之间的特征差距,分阶段可以让模型更稳定、泛化性更强,通过这种监督训练方法,StagedCRE能够在多模态数据上实现高效、准确的特征对齐。



1. 一种MRAG系统的多模态检索增强优化方法,其特征在于,MRAG系统采用分阶段训练策略,包括第一阶段的无监督训练及第二阶段有监督训练,其中,第一阶段的将输入的所模态数据的编码特征进行初步对齐,第二阶段的有监督训练进一步引导所有模态数据的编码特征对齐。

2. 如权利要求1所述MRAG系统的多模态检索增强优化方法,其特征在于,无监督训练阶段的损失函数具体如下:

$$\mathcal{L}_{align} = \mathcal{L}_{con} + \lambda_1 \mathcal{L}_{hsic} + \lambda_2 \mathcal{L}_{jsd};$$

其中, λ_1, λ_2 是用于平衡各损失项的超参数, $\mathcal{L}_{con}$ 表示知识库i中不同模态数据的语义特征的对比损失, $\mathcal{L}_{hsic}$ 表示知识库i中同模态下的对齐特征与上下文特征的独立性准则损失, $\mathcal{L}_{jsd}$ 表示知识库i中不同样本不同模态数据的JS散度对应的损失。

3. 如权利要求2所述MRAG系统的多模态检索增强优化方法,其特征在于,知识库i中不同模态数据的语义特征的对比损失 $\mathcal{L}_{con}$ 表示如下:

$$\mathcal{L}_{con} = - \sum_{m,n \in M, m \neq n} \log \left(\frac{\exp(\text{sim}(z_{ij}^{ma}, z_{ij}^{na}) / \tau)}{\sum_{j,k \in B, j \neq k} \exp(\text{sim}(z_{ij}^{ma}, z_{ik}^{na}) / \tau)} \right);$$

其中, $\text{sim}(z_{ij}^{ma}, z_{ij}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ij}^{na} 之间的余弦相似度, $\text{sim}(z_{ij}^{ma}, z_{ik}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ik}^{na} 之间的余弦相似度, z_{ik}^{na} 表示知识库i中模态为n的样本k的语义特征,M表示模态集合,B表示样本集合, τ 表示温度参数。

4. 如权利要求2所述MRAG系统的多模态检索增强优化方法,其特征在于,知识库i中同模态下的对齐特征与上下文特征的独立性准则损失 $\mathcal{L}_{hsic}$ 具体如下:

$$\mathcal{L}_{hsic} = \sum_{j \in B} \sum_{m \in M} HSIC(z_{ij}^{ma}, z_{ij}^{mc});$$

其中 $HSIC(z_{ij}^{ma}, z_{ij}^{mc})$ 表示对齐特征 z_{ij}^{ma} 与上下文特征 z_{ij}^{mc} 的独立性准则损失。

5. 如权利要求4所述MRAG系统的多模态检索增强优化方法,其特征在于,独立性准则损失 $HSIC(z_{ij}^{ma}, z_{ij}^{mc})$ 具体如下:

$$HSIC(z_{ij}^{ma}, z_{ij}^{mc}) = \frac{1}{(d-1)^2} \text{Tr} \left(K(z_{ij}^{ma}) H K(z_{ij}^{mc}) H \right);$$

其中, Tr 表示矩阵的迹, $K(z_{ij}^{ma})$ 、 $K(z_{ij}^{mc})$ 分别表示矩阵 z_{ij}^{ma} 、 z_{ij}^{mc} 在高斯核下的核矩阵, $H = I - \frac{1}{d} I$, I 为单位矩阵, d 表示超参数。

6. 如权利要求2所述MRAG系统的多模态检索增强优化方法,其特征在于,知识库i中不同样本不同模态数据的JS散度对应的损失 $\mathcal{L}_{jsd}$ 具体如下:

$$\mathcal{L}_{jsd} = \sum_{j,k \in B} \sum_{m,n \in M, m \neq n} JSD(z_{ij}^{mc}, z_{ik}^{nc});$$

其中, $JSD(z_{ij}^{mc}, z_{ik}^{nc})$ 表示上下文特征 z_{ij}^{mc} 与上下文特征 z_{ik}^{nc} 之间的JS散度, z_{ik}^{nc} 表示知识库 i 中模态为 n 的样本 k 的上下文特征。

7. 如权利要求2所述MRAG系统的多模态检索增强优化方法, 其特征在于, 有监督训练阶段的损失函数具体如下:

$$\mathcal{L}_{FGA} = \sum_{M=1}^M \frac{1}{M} \|z_m - z_{ref}\|_2^2;$$

其中, z_m 表示模态 m 的特征向量, z_{ref} 是从先验分布 $p(z)$ 中采样的随机参考向量。

8. 如权利要求7所述MRAG系统的多模态检索增强优化方法, 其特征在于, 使用标准高斯分布 $N(0, 1)$ 作为先验分布 $p(z)$ 。

9. 如权利要求7所述MRAG系统的多模态检索增强优化方法, 其特征在于, 针对每类知识库分别生成随机参考向量。

一种MRAG系统的多模态检索增强优化方法

技术领域

[0001] 本发明属于自学习技术领域,更具体地,本发明涉及一种基于MRAG系统的多模态检索增强优化方法。

背景技术

[0002] 大型语言模型(LLM, Large language models)在许多语言相关任务中取得了非凡的成就。通过在大量高质量的数据集上进行预训练,LLM可以学习各种语言模式、结构和事实知识。这些经过预训练的LLM可以生成类似人类的文本,具有高度的流畅性和连贯性,并在问题解答任务中表现出色,这表明它们有能力理解和回答各种询问。然而,尽管LLM的能力很强,但它仍然面临着很大的局限性。其中一个主要挑战在于它们在某个特定领域中的表现。虽然这些模型通常是在多样化和广泛的数据集上进行训练的,但这些数据集可能无法涵盖高度专业化领域或实时信息更新所需的知识深度。这可能会导致误导、错误甚至完全捏造的答案即幻觉现象,为了最大限度地减少幻觉的发生,对于提高LLM在不同领域提供准确且与上下文相关的信息的可靠性非常重要。

[0003] 检索增强生成(RAG, Retrieval-Augmented Generation)通过检索相关外部知识来增强LLM的生成能力,从而成为缓解幻觉的有效解决方案。现有的RAG系统通常分为两个步骤:检索和生成。以往对RAG系统的研究主要集中在由纯文本建立的知识库和在纯文本基础上预先训练的LLM,但随着多模态数据(如图像、音频等)的广泛应用,多模态RAG(MRAG, Multimodal Retrieval-Augmented Generation)系统的构建与优化的方案也渐渐出现。

[0004] 在MRAG系统中,核心是如何处理和利用多模态的非结构化和半结构化数据来提升大模型输出质量。目前的MRAG中比较常见的数据解析方案是基于提取的方法。该方法涉及两个步骤:首先从文档中提取多模态信息;其次对提取的数据进行解析和结构化,以便存储和下游使用。这种方式虽然简单,但是在将图像、音频等非文本数据转换为文本描述的过程中,往往会丢失原始数据中的细节信息。例如,图像中的颜色、流程图、空间布局等视觉细节,以及音频中的语调、节奏等声音特征,可能无法被完整地表达出来。这种信息的丢失限制了系统对多模态输入的深入理解和利用。而且数据在转换过程通常依赖于特定的模型(如OCR、图像描述生成器等),这些模型本身可能存在识别错误或生成不准确的问题。随着转换步骤的增加,误差可能会逐步累积,最终影响到检索和生成的质量。

发明内容

[0005] 鉴于此,本申请提供本发明提供一种多模态检索增强的优化方法,旨在改善上述问题中的至少一个。

[0006] 具体而言,包括以下的技术方案:

[0007] 一方面,本申请实施例提供了一种MRAG系统的多模态检索增强优化方法,MRAG系统采用分阶段训练策略,包括第一阶段的无监督训练及第二阶段有监督训练,其中,第一阶段的将输入的所模态数据的编码特征进行初步对齐,第二阶段的有监督训练进一步引导所

有模态数据的编码特征对齐。

[0008] 在本发明的一些实施例中,无监督训练阶段的损失函数具体如下:

$$[0009] \quad \mathcal{L}_{align} = \mathcal{L}_{con} + \lambda_1 \mathcal{L}_{hsic} + \lambda_2 \mathcal{L}_{jsd};$$

[0010] 其中, λ_1 、 λ_2 是用于平衡各损失项的超参数, $\mathcal{L}_{con}$ 表示知识库i中不同模态数据的语义特征的对比损失, $\mathcal{L}_{hsic}$ 表示知识库i中同模态下的对齐特征与上下文特征的独立性准则损失, $\mathcal{L}_{jsd}$ 表示知识库i中不同样本不同模态数据的JS散度对应的损失。

[0011] 在本发明的一些实施例中,知识库i中不同模态数据的语义特征的对比损失 $\mathcal{L}_{con}$ 表示如下:

$$[0012] \quad \mathcal{L}_{con} = - \sum_{m,n \in M, m \neq n} \log \left(\frac{\exp(\text{sim}(z_{ij}^{ma}, z_{ij}^{na}) / \tau)}{\sum_{j,k \in B, j \neq k} \exp(\text{sim}(z_{ij}^{ma}, z_{ik}^{na}) / \tau)} \right);$$

[0013] 其中, $\text{sim}(z_{ij}^{ma}, z_{ij}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ij}^{na} 之间的余弦相似度, $\text{sim}(z_{ij}^{ma}, z_{ik}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ik}^{na} 之间的余弦相似度, z_{ik}^{na} 表示知识库i中模态为n的样本k的语义特征,M表示模态集合,B表示样本集合, τ 表示温度参数。

[0014] 在本发明的一些实施例中,知识库i中同模态下的对齐特征与上下文特征的独立性准则损失 $\mathcal{L}_{hsic}$ 具体如下:

$$[0015] \quad \mathcal{L}_{hsic} = \sum_{j \in B} \sum_{m \in M} HSIC(z_{ij}^{ma}, z_{ij}^{mc});$$

[0016] 其中 $HSIC(z_{ij}^{ma}, z_{ij}^{mc})$ 表示对齐特征 z_{ij}^{ma} 与上下文特征 z_{ij}^{mc} 的独立性准则损失。

[0017] 在本发明的一些实施例中,独立性准则损失 $HSIC(z_{ij}^{ma}, z_{ij}^{mc})$ 具体如下:

$$[0018] \quad HSIC(z_{ij}^{ma}, z_{ij}^{mc}) = \frac{1}{(d-1)^2} \text{Tr} \left(K(z_{ij}^{ma}) H K(z_{ij}^{mc}) H \right);$$

[0019] 其中,Tr表示矩阵的迹, $K(z_{ij}^{ma})$ 、 $K(z_{ij}^{mc})$ 分别表示矩阵 z_{ij}^{ma} 、 z_{ij}^{mc} 在高斯核下的核矩阵, $H = I - \frac{1}{d}I$,I为单位矩阵,d表示超参数。

[0020] 在本发明的一些实施例中,知识库i中不同样本不同模态数据的JS散度对应的损失 $\mathcal{L}_{jsd}$ 具体如下:

$$[0021] \quad \mathcal{L}_{jsd} = \sum_{j,k \in B} \sum_{m,n \in M, m \neq n} JSD(z_{ij}^{mc}, z_{ik}^{nc});$$

[0022] 其中, $JSD(z_{ij}^{mc}, z_{ik}^{nc})$ 表示上下文特征 z_{ij}^{mc} 与上下文特征 z_{ik}^{nc} 之间的JS散度, z_{ik}^{nc} 表示知识库i中模态为n的样本k的上下文特征。

[0023] 在本发明的一些实施例中,有监督训练阶段的损失函数具体如下:

$$[0024] \quad \mathcal{L}_{FGA} = \sum_{M=1}^M \frac{1}{M} \|z_m - z_{ref}\|_2^2;$$

[0025] 其中, z_m 表示模态 m 的特征向量, z_{ref} 是从先验分布 $p(z)$ 中采样的随机参考向量。

[0026] 在本发明的一些实施例中, 使用标准高斯分布 $N(0, 1)$ 作为先验分布 $p(z)$ 。

[0027] 在本发明的一些实施例中, 针对每类知识库分别生成随机参考向量。

[0028] 本发明通过第一阶段的自监督学习可以初始化模型, 利用海量的无监督多模态数据, 让它获得较为稳健的模态内部表征; 第二阶段的基于FGA策略的对比学习更关注模态之间的对齐, 并且弥补了模态之间的特征差距, 分阶段可以让模型更稳定、泛化性更强, 通过这种监督训练方法, StagedCRE能够在多模态数据上实现高效、准确的特征对齐, 对齐的特征表示能够帮助模型更准确地理解用户查询与各种模态数据之间的语义关系, 从而提高检索的准确性和相关性。

附图说明

[0029] 为了更清楚地说明本申请实施例中的技术方案, 下面将对实施例描述中所需要使用的附图作简单地介绍, 显而易见地, 下面描述中的附图仅仅是本申请的一些实施例, 对于本领域普通技术人员来讲, 在不付出创造性劳动的前提下, 还可以根据这些附图获得其他的附图。

[0030] 图1为本发明实施例提供的MRAG系统的多模态检索增强优化方法的示意图;

[0031] 通过上述附图, 已示出本申请明确的实施例, 后文中将有更详细的描述。这些附图和文字描述并不是为了通过任何方式限制本申请构思的范围, 而是通过参考特定实施例为本领域技术人员说明本申请的概念。

具体实施方式

[0032] 下面将结合本申请实施例中的附图, 对本申请实施例中的技术方案进行清楚、完整地描述, 显然, 所描述的实施例是本申请一部分实施例, 而不是全部的实施例。基于本申请中的实施例, 本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例, 都属于本申请保护的范围。

[0033] 除非另有定义, 本申请实施例所用的所有技术术语均具有与本领域普通技术人员通常理解的相同的含义。

[0034] 为了更清晰说明本发明所提出的StagedCRE方法以及MRAG系统的背景, 这里对整个MRAG系统的目标进行数学形式化。具体来说, MRAG系统针对多模态输入 q 生成一个多模态或单模态的响应 r , 设 $D = \{d_1, d_2, \dots, d_n\}$ 为一个多模态语料库, 语料库中的每个文档 d_i 中包括至少一个数据模态, 将文档 d_i 的所有模态放入集合 M_{d_i} , 各种模态数据通过对应的编码器进行编码, 得到: $z_i = \text{Enc}_{M_{d_i}}(d_i)$, 所有编码表示的集合记为编码文本 $Z_{d_i} = \{z_1, z_2, \dots, z_n\}$ 。通过各模态数据的对应编码器将不同模态数据映射到共享语义空间, 以实现跨模态对齐。

[0035] 检索模型 R 用于评估每个编码文档 Z 相对于查询 q 的相关性, 表示为 $R(q, z)$, 为了构建检索增强的多模态上下文, 检索模型 R 根据模态对应的阈值选择最相关的文档:

$X = \{d_i | s(e_q, z_i) \geq \tau_{M_{d_i}}\}$, 其中, $\tau_{M_{d_i}}$ 是模态 M_{d_i} 对应的相关性阈值; e_q 是用户输入的查询 q 在共享语义空间中的编码表示; $s(e_q, z_i)$ 是衡量编码查询 e_q 与文档 z_i 表示之间相关性的评分函数。生成模型 G 在给定用户查询 q 和检索到的文档集 x 作为上下文时, 生成最终的多模态响

应 r ,即 $r=G(q,X)$ 。

[0036] 对于多模态数据中的文本数据,先使用BPE分词器进行分词,每个子词对应一个唯一的token,这些token都会映射到一个词嵌入层中,所有的tokens通过文本编码器编码,以获得文本对数输出 $y \in \mathbb{R}^{L \times C}$,其中, L 表示序列的长度, C 表示向量维度,用于文本编码器,使用从Open CLIP初始化的12层的Transformer模型,其维度为768。对于文本数据之外的其他模态,StagedCRE使用24层、1024维的Vision Transformer,编码器从Open CLIP-large进行初始化。音频数据被转换为持续时间为10秒(128个mel-bins)的频谱图,在处理音频数据时StagedCRE会对频谱图进行重复和填充。填充方案如下,4秒钟的频谱图会重复两次,然后用零填充额外的2秒钟。同样的,也会在通道维度上重复3次。如果持续时间超过10秒,则会从原始音频的前1/3、中1/3和后1/3处随机取样3个10秒的音频片段,最后将它们堆叠在一起。为了确保不同模态之间的对齐,StagedCRE使用对比学习的方式。这种方法的目标是增加配对数据的相似性,使其更接近同一语义空间,同时最小化非配对数据的相似性。StagedCRE的主要思想就是利用对比学习的方式将其他模态的数据对齐到文本模态。

[0037] 本发明提出了一种基于统一表征的多模态检索增强系统优化方法,其中,阶段式跨模态表征模型训练架构(StagedCRE, Staged Cross-Modal Representation Enhancement)极大程度缓解了MRAG系统中由于检索模块的特征向量的语义表达缺陷而导致的性能降低。StagedCRE通过将自监督与对比学习结合的一种跨模态的表征对齐训练框架,StagedCRE通过两阶段的训练,图1为本发明实施例提供的MRAG系统的多模态检索增强优化方法的示意图,该方法具体如下:

[0038] MRAG系统采用分阶段训练策略,包括第一阶段的无监督训练及第二阶段有监督训练,其中,第一阶段的将输入的所模态数据的编码特征进行初步对齐,第二阶段的有监督训练进一步引导所有模态数据的编码特征对齐。

[0039] 在StagedCRE的无监督训练阶段,使用了一种用于多模态数据的无监督对齐策略,旨在捕捉模态间的共享信息,同时利用未标注的海量数据、减少噪声数据的影响,提高检索模型R的性能进而提高MRAG系统的能力。对于来自不同数据源即MRAG系统中不同领域的知识库 i ,模态为 m 的样本 j ,StagedCRE首先通过编码器将其输入数据 x_{ij}^m 映射为特征表示 $z_{ij}^m = \mathcal{E}_{im}(x_{ij}^m)$, $\mathcal{E}_{im}$ 表示知识库 i 中模态 m 的编码器,假设特征维度为 $2d$,则 z_{ij}^m 的定义如下: $z_{ij}^{ma} = z_{ij}^m[0:d]$, $z_{ij}^{mc} = z_{ij}^m[d:2d]$,其中, z_{ij}^{ma} 表示语义特征,用于捕捉模态 m 的核心语义信息;而 z_{ij}^{mc} 表示模态 m 的上下文特征,用于编码辅助信息或噪声信息。

[0040] 为了促进不同模态之间的对齐,提取不同模态之间的互补信息,同时利用大量的未标注数据,无监督训练阶段采用无监督对比学习目标,利用未进行人工标注的样本来增强来源于模态 m 和模态 n 中的同一样本 j 的语义特征 z_{ij}^{ma} 、 z_{ij}^{na} 之间的一致性,可以为样本 j 中模态 m 和模态 n 的数据,其中, $m, n \in M$, M 为模态集合,详细来说,在给定一批样本 $B \in D_i$ 的情况下, D_i 表示知识库 i 中的样本数据,第一阶段的学习目标定义如下:

$$[0041] \quad \mathcal{L}_{con} = - \sum_{m, n \in M, m \neq n} \log \left(\frac{\exp(\text{sim}(z_{ij}^{ma}, z_{ij}^{na}) / \tau)}{\sum_{j, k \in B, j \neq k} \exp(\text{sim}(z_{ij}^{ma}, z_{ik}^{na}) / \tau)} \right);$$

[0042] 其中, $\mathcal{L}_{con}$ 表示知识库i中不同模态数据的语义特征的对比损失, $\text{sim}(z_{ij}^{ma}, z_{ij}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ij}^{na} 之间的余弦相似度, $\text{sim}(z_{ij}^{ma}, z_{ik}^{na})$ 表示语义特征 z_{ij}^{ma} 与语义特征 z_{ik}^{na} 之间的余弦相似度, z_{ik}^{na} 表示知识库i中模态为n的样本k的语义特征, M表示模态集合, B表示样本集合, τ 表示温度参数, 模型通过最小化 $\mathcal{L}_{con}$, 约束来自同一样本的不同模态的对齐特征在特征空间中彼此接近, 从而增强多模态特征对齐能力。

[0043] 为了确保模态m上样本j的对齐特征 z_{ij}^{ma} 与上下文特征 z_{ij}^{mc} 捕捉到相对独立的语义信息, 在训练目标中额外引入Hilbert-Schmidt独立性准则 (HSIC) 来约束表征之间的统计依赖性。给定一批来自 D_i 的样本集合B, 独立性损失定义为:

$$[0044] \quad \mathcal{L}_{hsic} = \sum_{j \in B} \sum_{m \in M} HSIC(z_{ij}^{ma}, z_{ij}^{mc});$$

[0045] 其中, $\mathcal{L}_{hsic}$ 表示知识库i中同模态下的对齐特征与上下文特征的独立性准则损失, $HSIC(z_{ij}^{ma}, z_{ij}^{mc})$ 表示对齐特征 z_{ij}^{ma} 与上下文特征 z_{ij}^{mc} 的独立性准则损失。

$$[0046] \quad HSIC(z_{ij}^{ma}, z_{ij}^{mc}) = \frac{1}{(d-1)^2} \text{Tr} \left(K(z_{ij}^{ma}) H K(z_{ij}^{mc}) H \right);$$

[0047] 其中, Tr表示矩阵的迹, $K(z_{ij}^{ma})$ 、 $K(z_{ij}^{mc})$ 分别表示矩阵 z_{ij}^{ma} 、 z_{ij}^{mc} 在高斯核下的核矩阵, $H = I - \frac{1}{d}$, 其中, I为单位矩阵, d表示超参数。

[0048] 为了保证不同样本及不同模态之间的上下文特征 z_{ij}^{mc} 与 z_{ik}^{nc} 的多样性, 防止它们趋同于与任务无关的信息, 在训练目标的设计上另外引入了JS散度 (JSD) 作为约束。给定样本集合B, 损失函数定义如下所示:

$$[0049] \quad \mathcal{L}_{jsd} = \sum_{j, k \in B} \sum_{m, n \in M, m \neq n} JSD(z_{ij}^{mc}, z_{ik}^{nc});$$

[0050] 其中, $\mathcal{L}_{jsd}$ 表示知识库i中不同样本不同模态数据的JS散度对应的损失, $JSD(z_{ij}^{mc}, z_{ik}^{nc})$ 表示上下文特征 z_{ij}^{mc} 与上下文特征 z_{ik}^{nc} 之间的JS散度, z_{ik}^{nc} 表示知识库i中模态为n的样本k的上下文特征; 通过最小化 $\mathcal{L}_{jsd}$, 可确保上下文特征在不同模态与样本间保持丰富多样, 有效保存多模态数据的信息多样性。

[0051] 综上所述, 对于无监督对比特征对齐的总体训练目标记作 $\mathcal{L}_{align}$, 无监督训练阶段的损失函数表示如下:

$$[0052] \quad \mathcal{L}_{align} = \mathcal{L}_{con} + \lambda_1 \mathcal{L}_{hsic} + \lambda_2 \mathcal{L}_{jsd};$$

[0053] 其中, λ_1 、 λ_2 是用于平衡各损失项的超参数。

[0054] 在完成无监督预训练阶段后, 为了进一步实现全模态表征的精细对齐, StagedCRE在第二阶段进行了监督训练。StagedCRE的设计旨在有效地整合多模态信息, 为后续的多模态检索和问答系统应用提供高质量的特征表示。

[0055] 为了实现多模态特征的有效对齐, 在StagedCRE的监督训练阶段提出了一种特征

引导对齐 (Feature Guided Alignment, FGA) 策略。FGA 的核心思想是通过引入随机参考向量, 引导不同模态的特征分布逐渐对齐到一个共享的先验分布上, 简单来说就是约束模型匹配特征分布而非直接匹配成对特征。具体而言, FGA 从一个预定义的先验分布 $p(z)$, 例如标准高斯分布 $N(0, 1)$, 中采样随机参考向量 z_{ref} , 对模态 m 进行特征编码, 获得模态特征向量 z_m , 计算模态特征向量 z_m 与该参考向量之间的距离。StagedCRE 通过最小化这种距离促使不同模态的特征在特征空间中向同一分布对齐。在本发明实施例中, FGA 默认使用标准高斯分布 $N(0, 1)$ 作为先验分布 $p(z)$, FGA 的损失函数定义如下:

$$[0056] \quad \mathcal{L}_{FGA} = \sum_{m=1}^M \frac{1}{M} \|z_m - z_{ref}\|_2^2;$$

[0057] 其中, z_m 表示模态 m 的特征向量, z_{ref} 是从先验分布 $p(z)$ 中采样的随机参考向量, 其中, $E(x_1, x_2, \dots, x_M \in D) = z_1, z_2, \dots, z_M$, D 是用于监督训练的不同知识库中的多模态数据集, $E(x_1, x_2, \dots, x_M \in D)$ 表示通过模态 m 对应的编码器对数据 x_m 进行编码后, 获得特征向量 z_m 。这种设计不仅能够有效减少不同模态之间的特征差距, 还能通过随机采样引入的正则化效果提高模型的泛化能力。通过这一损失函数, StagedCRE 可以实现通过与每个多模态数据对之间共享的 z_{ref}^i 间接最小化模态间的差异, 其中, z_{ref}^i 表示知识库 i 的随机参考向量, 不同知识库的随机参考向量不同, 并且特征向量逐渐遵循共享的先验分布 $p(z)$ 。

[0058] 本发明提供的 MRAG 系统的多模态检索增强优化方法具有如下有益技术效果:, StagedCRE 优势在于

[0059] (1) 第一阶段的自监督学习可以初始化模型, 利用海量的无监督多模态数据, 让它获得较为稳健的模态内部表征; 第二阶段的基于 FGA 策略的对比学习更关注模态之间的对齐, 并且弥补了模态之间的特征差距, 分阶段可以让模型更稳定、泛化性更强, 通过这种监督训练方法, StagedCRE 能够在多模态数据上实现高效、准确的特征对齐;

[0060] (2) 对齐的特征表示能够帮助模型更准确地理解用户查询与各种模态数据之间的语义关系, 从而提高检索的准确性和相关性;

[0061] (3) 本发明提出的 StagedCRE 全模态表征对齐框架适用于多模态检索和问答系统。在多模态检索中, 在问答系统中, 对齐的多模态特征使得模型能够同时利用图像、文本等多种信息源, 更全面地理解和回答用户的问题;

[0062] 综上所述, 本发明所提出的 StagedCRE 训练框架可以充分利用各种模态的未标注数据, 并且引入合理约束来提高表征之间的对齐度, 有效的减少了模态差距, 提高了 MRAG 系统的整体性能。

[0063] 本领域技术人员在考虑说明书及实践这里公开的本申请后, 将容易想到本申请的其它实施方案。本申请旨在涵盖本申请的任何变型、用途或者适应性变化, 这些变型、用途或者适应性变化遵循本申请的一般性原理并包括本申请未公开的本技术领域中的公知常识或惯用技术手段。说明书和实施例仅被视为示例性的。

[0064] 应当理解的是, 本申请并不局限于上面已经描述并在附图中示出的精确结构, 并且可以在不脱离其范围进行各种修改和改变。本申请的范围仅由所附的权利要求来限制。



图1