



(12) 发明专利申请

(10) 申请公布号 CN 121303124 A

(43) 申请公布日 2026. 01. 09

(21) 申请号 202511389816.2

G06Q 30/0282 (2023.01)

(22) 申请日 2025.09.26

(71) 申请人 芜湖奇瑞信息技术有限公司

地址 241000 安徽省芜湖市经济技术开发区
区长春路8号

申请人 奇瑞汽车股份有限公司

(72) 发明人 徐伟风 陈煜 乔伟 罗锐 戴闯

(74) 专利代理机构 芜湖安汇知识产权代理有限公司 34107

专利代理师 钟雪

(51) Int. Cl.

G06F 40/284 (2020.01)

G06F 40/186 (2020.01)

G06N 3/045 (2023.01)

G06N 3/096 (2023.01)

权利要求书2页 说明书5页 附图1页

(54) 发明名称

一种提示词优化方法

(57) 摘要

本发明提供了一种提示词优化方法,该方法具体如下:选择多个语言模型作为教师模型,将训练好的教师模型的学习能力蒸馏至学生模型,学生模型的参数量远小于教师模型;将用户的评论信息输入BM25模型,BM25模型提取与评论信息关联度高的质量标签和口碑标签,将提取到的质量标签和口碑标签放入提示词模板中,蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签。为了减少对硬件资源的依赖,通过模型蒸馏方式降低模型参数量,同时,为了平衡参数量的下降可能带来模型能力损失,采用模型集成蒸馏的方式进行;为了提高多标签提取的准确率,通过引入BM25等技术自适应调整提示词长度缓解指令遵循问题。

选择多个语言模型作为教师模型,将训练好的教师模型的学习能力蒸馏至学生模型,学生模型的参数量小于教师模型

将用户的评论信息输入BM25模型,BM25模型提取与评论信息关联度高的质量标签和口碑标签,将提取到的质量标签和口碑标签放入提示词模板中

蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签

1. 一种提示词优化方法,其特征在于,所述方法具体如下:

(1) 选择多个语言模型作为教师模型,将训练好的教师模型的学习能力蒸馏至学生模型,学生模型的参数量远小于教师模型;

(2) 将用户的评论信息输入BM25模型,BM25模型提取与评论信息关联度高的质量标签和口碑标签,将提取到的质量标签和口碑标签放入提示词模板中,蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签。

2. 如权利要求1所述提示词优化方法,其特征在于,基于各教师模型在验证集上的标签提取准确率确定各教师模型的权重,对各教师模型输出的标签及其概率进行加权融合,将输出的标签及加权融合后的概率进行输出;

其中,标签包括质量标签及口碑标签。

3. 如权利要求2所述提示词优化方法,其特征在于,在学生模型的训练过程中,基于损失函数调整学生模型的模型参数,使得学生模型的预测输出趋向于教师模型的输出,其中的损失函数 L_{distill} 具体如下:

$$L_{\text{distill}} = -\sum_k P_{\text{final}}(k) (\log(Y_{\text{student}}(k)))$$

其中, $P_{\text{final}}(k)$ 表示教师模型针对样本k的预测输出, $Y_{\text{student}}(k)$ 为学生模型针对样本k的预测输出。

4. 如权利要求2所述提示词优化方法,其特征在于,在学生模型的训练过程中,教师模型包括:第一个教师模型、第二教师模型及第三教师模型,第一个教师模型、第二教师模型及第三教师模型分别为DeepSeek v3模型、Qwen3模型及ChatGLM模型。

5. 如权利要求1所述提示词优化方法,其特征在于,将人工整理的预定义的质量标签和口碑标签进行向量化,将向量化后的质量标签和口碑标签存储至标签数据库中,BM25模型从标签数据库中提取与当前输入的评论信息关联度高的质量标签及口碑标签。

6. 如权利要求1所述提示词优化方法,其特征在于,对提示词的质量进行评分,将评分高的提示词输出至蒸馏后的学生模型。

7. 如权利要求6所述提示词优化方法,其特征在于,提示词的评分更新方法具体如下:

采集用户对提示词的反馈,包括正向反馈及负向反馈;

统计用户对各个提示词的正向反馈次数 k_1 及负向反馈次数 k_2 ,基于正向反馈次数 k_1 及负向反馈次数 k_2 来更新提示词当前的评分。

8. 如权利要求7所述提示词优化方法,其特征在于,基于正向反馈次数 k_1 的提示词当前评分更新方法具体如下:

$$w_n = w_o \times (1 - \lambda) + \Delta w_{\text{like}}$$

其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, λ 为衰减因子, Δw_{like} 为正向反馈次数 k_1 对应评分增量,评分增量 Δw_{like} 的计算公式具体如下:

$$\Delta w_{\text{like}} = \alpha \cdot \log(k_1 + 1)$$

其中, α 是一个超参数,且 $0 < \alpha < 1$ 。

9. 如权利要求7所述提示词优化方法,其特征在于,基于负向反馈次数 k_2 的提示词当前评分更新方法具体如下:

$$w_n = w_o \times (1 - \beta) - \Delta w_{\text{edit}}$$

其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, β 为衰减因子, Δw_{eidt} 为负向反馈次数 k_2 对应评分增量, 评分增量 Δw_{eidt} 的计算公式具体如下:

$$\Delta w_{eidt} = -\gamma \cdot \log(k_2 + 1)$$

其中, γ 是一个超参数, 且 $0 < \gamma < 1$ 。

10. 如权利要求5所述提示词优化方法, 其特征在于, 样本的构建过程具体如下:

从指定网站上抓取用户的评论信息, 对抓取到的评论信息进行预处理;

标记每条评论信息的质量标签及口碑标签, 将标记后的评论信息作为样本存储至样本集中。

一种提示词优化方法

技术领域

[0001] 本发明属于自学习技术领域,更具体地,本发明涉及一种提示词优化方法。

背景技术

[0002] 汽车领域客户之声(Voice of the Customer,VOC)通过多种渠道收集的客户端对品牌、产品、服务等各方面的反馈,包括投诉、建议、评价、情绪、期望等。它贯穿客户全生命周期,从购车前的品牌认知,到购车过程、用车体验、售后服务等各环节。

[0003] 通过采集汽车之家、懂车帝等的客户端反馈及评论相关信息,从客户端反馈及评论相关信息提取质量标签和口碑标签,便于快速的了解客户端的需求、偏好和不满意之处,从而改进产品或服务。

[0004] 基于大语言模型的提示词方法在标签提取上的能力主要取决于大模型本身能力和提示词设计的优劣。一般来说大模型参数量越大,模型能力越强,但相应的对硬件能力要求也就越高。比如DeepSeek v3有6710亿参数,要求:GPU:8×NVIDIA H100 80GB(NVLink互联)或16×A100 80GB,显存总和≥640GB(FP16精度)。CPU:64核以上(如AMD EPYC 96核),内存≥512GB DDR5。这个成本相对较高,很多企业无法接受。从提示词维度来说,如果预定义标签数量过于庞大,很容易出现指令遵循差的现象,导致最终多标签提取准确率受限。

发明内容

[0005] 鉴于此,本申请提供本发明提供一种提示词优化方法,旨在改善上述问题中的至少一个。

[0006] 具体而言,包括以下的技术方案:

[0007] 一方面,本申请实施例提供了一种提示词优化方法,所述方法具体如下:

[0008] (1)选择多个语言模型作为教师模型,将训练好的教师模型的学习能力蒸馏至学生模型,学生模型的参数量远小于教师模型;

[0009] (2)将用户的评论信息输入BM25模型,BM25模型提取与评论信息关联度高的质量标签和口碑标签,将提取到的质量标签和口碑标签放入提示词模板中,蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签。

[0010] 在本发明的一些实施例中,基于各教师模型在验证集上的标签提取准确率确定各教师模型的权重,对各教师模型输出的标签及其概率进行加权融合,将输出的标签及加权融合后的概率进行输出;

[0011] 其中,标签包括质量标签及口碑标签。

[0012] 在本发明的一些实施例中,在学生模型的训练过程中,基于损失函数调整学生模型的模型参数,使得学生模型的预测输出趋向于教师模型的输出,其中的损失函数 $L_{distill}$ 具体如下:

$$[0013] \quad L_{distill} = -\sum_k P_{final}(k)(\log(Y_{student}(k)))$$

[0014] 其中, $P_{\text{final}}(k)$ 表示教师模型针对样本 k 的预测输出, $Y_{\text{student}}(k)$ 为学生模型针对样本 k 的预测输出。

[0015] 在本发明的一些实施例中, 在学生模型的训练过程中, 教师模型包括: 第一个教师模型、第二教师模型及第三教师模型, 第一个教师模型、第二教师模型及第三教师模型分别为 DeepSeek v3 模型、Qwen3 模型及 ChatGLM 模型。

[0016] 在本发明的一些实施例中, 将人工整理的预定义的质量标签和口碑标签进行向量化, 再将向量化后的质量标签和口碑标签存储至标签数据库中, BM25 模型从标签数据库中提取与当前输入的评论信息关联度高的质量标签及口碑标签。

[0017] 在本发明的一些实施例中, 对提示词的质量进行评分, 将评分高的提示词输出至蒸馏后的学生模型。

[0018] 在本发明的一些实施例中, 提示词的评分更新方法具体如下:

[0019] 采集用户对提示词的反馈, 包括正向反馈及负向反馈;

[0020] 统计用户对各个提示词的正向反馈次数 k_1 及负向反馈次数 k_2 , 基于正向反馈次数 k_1 及负向反馈次数 k_2 来更新提示词当前的评分。

[0021] 在本发明的一些实施例中, 基于正向反馈次数 k_1 的提示词当前评分更新方法具体如下:

[0022] $w_n = w_o \times (1 - \lambda) + \Delta w_{\text{like}}$

[0023] 其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, λ 为衰减因子, Δw_{like} 为正向反馈次数 k_1 对应评分增量, 评分增量 Δw_{like} 的计算公式具体如下:

[0024] $\Delta w_{\text{like}} = \alpha \cdot \log(k_1 + 1)$

[0025] 其中, α 是一个超参数, 且 $0 < \alpha < 1$ 。

[0026] 在本发明的一些实施例中, 基于负向反馈次数 k_2 的提示词当前评分更新方法具体如下:

[0027] $w_n - w_o \times (1 - \beta) = \Delta w_{\text{eidt}}$

[0028] 其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, β 为衰减因子, Δw_{eidt} 为负向反馈次数 k_2 对应评分增量, 评分增量 Δw_{eidt} 的计算公式具体如下:

[0029] $\Delta w_{\text{eidt}} = -\gamma \cdot \log(k_2 + 1)$

[0030] 其中, γ 是一个超参数, 且 $0 < \gamma < 1$ 。

[0031] 在本发明的一些实施例中, 样本的构建过程具体如下:

[0032] 从指定网站上抓取用户的评论信息, 对抓取到的评论信息进行预处理;

[0033] 标记每条评论信息的质量标签及口碑标签, 将标记后的评论信息作为样本存储至样本集中。

[0034] 本发明提供的提示词优化方法具有如下有益技术效果:

[0035] (a) 为了减少对硬件资源的依赖, 通过模型蒸馏方式降低模型参数量, 同时, 为了平衡参数量的下降可能带来模型能力损失, 采用模型集成蒸馏的方式进行;

[0036] (b) 为了提高多标签提取的准确率, 通过引入 BM25 等技术自适应调整提示词长度缓解指令遵循问题, 为了提高多标签提取的准确性及泛化性, 通过分析用户行为反馈 (点赞、取消或修改) 来调整后续生成的提示词, 不断提升多标签提取的准确率。

附图说明

[0037] 为了更清楚地说明本申请实施例中的技术方案,下面将对实施例描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是本申请的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0038] 图1为本发明实施例提供的提示词优化方法流程图;

[0039] 通过上述附图,已示出本申请明确的实施例,后文中将有更详细的描述。这些附图和文字描述并不是为了通过任何方式限制本申请构思的范围,而是通过参考特定实施例为本领域技术人员说明本申请的概念。

具体实施方式

[0040] 下面将结合本申请实施例中的附图,对本申请实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例是本申请一部分实施例,而不是全部的实施例。基于本申请中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本申请保护的范围。

[0041] 除非另有定义,本申请实施例所用的所有技术术语均具有与本领域普通技术人员通常理解的相同的含义。

[0042] 图1为本发明实施例提供的提示词优化方法流程图,该方法具体如下:

[0043] (1) 选择多个语言模型作为教师模型,通过样本对教师模型进行训练,将教师模型的学习能力蒸馏至学生模型,学生模型的参数量远小于教师模型;

[0044] 在本发明实施例中,样本为客户的评论信息及评论信息对应的质量标签及口碑标签,其中,质量标签为评论信息中提及到的车辆质量问题,口碑标签为评论信息中提及到的车辆评价信息,其中,样本的构建过程具体如下:

[0045] (11) 从指定网站上抓取用户的评论信息,对抓取到的评论信息进行预处理,预处理包括:同一数据格式,剔除特殊字符,过滤广告数据等;

[0046] (12) 标记每条评论信息的质量标签及口碑标签,将标记后的评论信息作为样本存储至样本集中。

[0047] 在本发明实施例中,下列评论信息1、评论信息2及评论信息3是从汽车相关公开网站爬取到的用户评论信息,汽车相关公开网站包括:汽车之家、懂车帝等,下面以评论信息1、评论信息2及评论信息3为例说明质量标签及口碑标签的标注,具体如下:

[0048] 评论信息1:车机系统不更新,a柱风声大,希望厂家处理。评论信息1的质量标签为A柱、B柱、C柱或D柱异响,口碑标签为车机长时间不发布升级;

[0049] 评论信息2:真的,这车型都改款了就不能把双联屏换下去,双联屏有多少库存啊[我想静静]。评论信息2的质量标签为无,口碑标签为中控台设计不好看;

[0050] 评论信息3:1新版本砍动力2油混有顿挫3急加速会出现发动机干吼动力短暂缺失4连接hicar手机提示音车机会会有卡碟片的声音5车机地图一直不更新6反应多次一直推脱未解决,评论信息1的质量标签为变速箱/车辆换挡冲击/顿挫,以及车辆失速/失去动力,口碑标签为互相推诿、车机长时间不发布升级以及发动机/增程器噪音大。

[0051] 在本发明实施例中,选择模型参数大的语言模型作为教师模型,选择模型参数少

的语言模型作为学生模型,将多个教师模型的学习结果通过加权平均的方式进行融合,不同教师模型分别代表不同的架构和学习策略,可以从不同角度捕捉数据的特征,保证学生模型获取更多样化的知识,以便降低模型对硬件资源依赖,同时提高泛化能力和准确性。

[0052] 在本发明实施例中,将样本集中的样本按照设定的比例划分为训练集、验证集及测试集,基于训练集中的样本分别对三个教师模型进行训练,基于验证集对三个教师模型进行测试,基于各教师模型在验证集上的标签提取准确率确定各教师模型的权重,对各教师模型输出的标签及其概率进行加权融合,将输出的标签及加权融合后的概率进行输出,其中,标签包括质量标签及口碑标签。

[0053] 本发明以三个教师模型为例进行说明,教师模型包括:第一个教师模型、第二教师模型及第三教师模型,检测三个教师模型在验证集上的标签提取准确率,将标签提取准确率高的教师模型赋予较大权值,反之,标签提取准确率低的教师模型赋予较小权值,三个教师模型的权重分别为 w_1 、 w_2 、 w_3 ,教师模型输出的标签 j 及其加权融合后的概率 P_j 具体如下:

$$[0054] \quad P_{final_j} = w_1 P_{1j} + w_2 P_{2j} + w_3 P_{3j} \quad (1)$$

[0055] 其中, w_1 、 P_{1j} 分别表示第一个教师模型的权重、第一个教师模型输出标签 j 的概率; w_2 、 P_{2j} 分别表示第二个教师模型的权重、第二个教师模型输出标签 j 的概率; w_3 、 P_{3j} 分别表示第三个教师模型的权重、第三个教师模型输出标签 j 的概率,其中,第一个教师模型、第二教师模型及第三教师模型分别为DeepSeek v3模型、Qwen3模型及ChatGLM模型。

[0056] 基于训练样本对学生模型进行训练,基于损失函数来调整学生模型的模型参数,使得学生模型的预测输出趋向于教师模型的预测输出,本发明采用交叉熵损失函数衡量学生模型与教师模型的预测输出之间的差异,交叉熵损失函数 $L_{distill}$ 的计算公式如下:

$$[0057] \quad L_{distill} = - \sum_k P_{final}(k) (\log(Y_{student}(k))) \quad (2)$$

[0058] 其中, $P_{final}(k)$ 表示教师模型针对样本 k 的预测输出, $Y_{student}(k)$ 为学生模型针对样本 k 的预测输出。

[0059] (2) 将用户的评论信息输入BM25模型,BM25模型提取与评论信息关联度高的质量标签和口碑标签,将提取到的质量标签和口碑标签放入提示词模板中,蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签。

[0060] 在本发明实施例中,构建标签数据库,将预定义的质量标签及口碑标签进行向量化,将向量化后质量标签和口碑标签分别存储至标签数据库中,BM25模型从标签数据库中提取出当前输入的评论信息关联度高的质量标签和口碑标签,将这部分质量标签和口碑标签放入提示词模板中,蒸馏后的学生模型基于提示词提取评论信息对应质量标签和口碑标签,蒸馏后的学生模型因为模型参数较少,学习能力交较弱,在提示词模板中标签的数量过多时,学生模型的能力无法完成大量标签的学习,因此,先通过BM25模型对标签进行初步的筛选,以降低学生模型需要学习的标签数量,进而提高的学生模型的学习能力。

[0061] 在本发明实施例中,为了便于评价每个提示词的质量,针对每个提示词设计了评分及评分更新方法,将评分高的提示词输出至蒸馏后的学生模型,其中,提示词的评分更新方法具体如下:

[0062] (21) 采集用户对提示词的反馈,包括正向反馈及负向反馈,正向反馈为对提示词的认可,负向反馈为提示词不符合预期;

[0063] (22) 统计各个提示词的正向反馈次数 k_1 及负向反馈次数 k_2 ,基于正向反馈次数 k_1 及负向反馈次数 k_2 来更新提示词当前的评分,若对应提示词不存在正向反馈及负向反馈,则不更新对应提示词当前的评分 w_o ,对评分过低的提示词进行修正,以提高提示词的质量,便于学生模型能更好进行提示词的学习。

[0064] 在本发明实施例中,基于正向反馈次数 k_1 的提示词当前评分更新方法具体如下:

$$w_n = w_o \times (1 - \lambda) + \Delta w_{like} \quad (3)$$

[0066] 其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, λ 为衰减因子, Δw_{like} 为正向反馈次数 k_1 对应评分增量,评分增量 Δw_{like} 的计算公式具体如下:

$$\Delta w_{like} = \alpha \cdot \log(k_1 + 1) \quad (4)$$

[0068] 其中, α 是一个超参数,用来调节正向反馈的影响程度,且 $0 < \alpha < 1$ 。

[0069] 在本发明实施例中,基于负向反馈次数 k_2 的提示词当前评分更新方法具体如下:

$$w_n = w_o \times (1 - \beta) - \Delta w_{eidt} \quad (5)$$

[0071] 其中, w_o 为提示词当前的评分, w_n 为提示词更新后的评分, β 为衰减因子, Δw_{eidt} 为负向反馈次数 k_2 对应评分增量,评分增量 Δw_{eidt} 的计算公式具体如下:

$$\Delta w_{eidt} = -\gamma \cdot \log(k_2 + 1) \quad (6)$$

[0073] 其中, γ 是一个超参数,用来调节负向反馈的影响程度,且 $0 < \gamma < 1$ 。

[0074] 本发明提供的提示词优化方法具有如下有益技术效果:

[0075] (a) 为了减少对硬件资源的依赖,通过模型蒸馏方式降低模型参数量,同时,为了平衡参数数量的下降可能带来模型能力损失,采用模型集成蒸馏的方式进行;

[0076] (b) 为了提高多标签提取的准确率,通过引入BM25等技术自适应调整提示词长度缓解指令遵循问题,为了提高多标签提取的准确性及泛化性,通过分析用户行为反馈(点赞、取消或修改)来调整后续生成的适合提示词,不断提升标签准提取的准确率。

[0077] 综上所述,提升VOC中多标签提取的准确率以及减少模型对硬件资源的依赖进而提升模型应用范围。

[0078] 本领域技术人员在考虑说明书及实践这里公开的本申请后,将容易想到本申请的其它实施方案。本申请旨在涵盖本申请的任何变型、用途或者适应性变化,这些变型、用途或者适应性变化遵循本申请的一般性原理并包括本申请未公开的本技术领域中的公知常识或惯用技术手段。说明书和实施例仅被视为示例性的。

[0079] 应当理解的是,本申请并不局限于上面已经描述并在附图中示出的精确结构,并且可以在不脱离其范围进行各种修改和改变。本申请的范围仅由所附的权利要求来限制。




图1