



(12)发明专利申请

(10)申请公布号 CN 107609588 A

(43)申请公布日 2018.01.19

(21)申请号 201710816581.X

(22)申请日 2017.09.12

(71)申请人 大连大学

地址 116622 辽宁省大连市开发区学府大街10号

(72)发明人 张强 张建新 徐伟风 魏小鹏

(74)专利代理机构 大连八方知识产权代理有限公司 21226

代理人 卫茂才

(51)Int.Cl.

G06K 9/62(2006.01)

G10L 15/02(2006.01)

A61B 5/00(2006.01)


权利要求书1页 说明书6页 附图1页

(54)发明名称

一种基于语音信号的帕金森患者UPDRS得分预测方法

(57)摘要

本发明涉及一种基于语音信号的帕金森患者UPDRS得分预测方法。包括如下步骤：首先，基于大量的语音信号特征数据，分别使用三种特征选择方法选择语音信号特征，获得三组特征子集；其次，采用绝对多数投票法将三组特征子集进行集成，集成后的特征子集为最终特征子集；然后，将最终特征子集作为聚类算法k-means的输入，将相似的帕金森患者聚在一起，利用肘部法则及轮廓系数确定聚类的数目；最后，利用相似患者构建个性化预测模型，为每个帕金森患者定制预测方法，根据帕金森患者语音信号的特征，选择对应的回归算法。本发明采用集成特征选择和相似患者预测的方法，构建一种个性化预测模型的框架，可提高帕金森患者UPDRS得分的预测精度，具有较好的鲁棒性。



1. 一种基于语音信号的帕金森患者UPDRS得分预测方法,其特征在于,该方法包括以下步骤:

步骤1:基于大量的语音信号特征数据,分别使用过滤式、包裹式、嵌入式三种特征选择方法选择语音信号特征,获得三组特征子集;

步骤2:采用绝对多数投票的结合策略将基于步骤1得到的三组特征子集进行集成,选择集成后的特征子集作为最终的特征子集;

步骤3:将基于步骤2得到的最终的特征子集作为聚类算法k-means的输入,将相似的帕金森患者聚在一起,并利用肘部法则及轮廓系数确定聚类的数目;

步骤4:基于步骤3,根据待预测帕金森患者的特征将其划分到相应的类别中,利用相似患者构建个性化预测模型,根据患者个体特征的不同选择相对应的回归算法预测UPDRS得分。

2. 根据权利要求1所述的一种基于语音信号的帕金森患者UPDRS得分预测方法,其特征在于,步骤2结合策略采用的绝对多数投票法的公式为:

$$H(\vec{x}) = \begin{cases} c_j, & \sum_{i=1}^T h_i^j(\vec{x}) > 0.5 \sum_{k=1}^N \sum_{i=1}^T h_i^k(\vec{x}) \\ \text{reject}, & \text{otherwise.} \end{cases}$$

其中 h_i 表示特征选择方法,在每个特征选择方法上的预测输出表示为一个N维向量 $(h_i^1(\vec{x}); h_i^2(\vec{x}); \dots; h_i^N(\vec{x}))$;特征子集集合 $\{c_1, c_2, \dots, c_N\}$,其中 c_j 表示特征标记; $h_i^j(\vec{x})$ 表示 h_i 在特征标记 c_j 上的输出,输出结果为1或0,其中1表示选择对应位置的特征,0表示不选择对应位置的特征,若该标记得票过半数,则预测为该标记,否则拒绝预测。

3. 根据权利要求1所述的一种基于语音信号的帕金森患者UPDRS得分预测方法,其特征在于,将基于步骤2得到的集成特征选择方法选择出的最终特征子集 $\{c_1, c_2, \dots, c_N\}$ 作为k-means算法的输入,根据欧氏距离将相似的患者聚集在一起,公式如下:

$$\arg \min \sum_{i=1}^k \sum_{\vec{x} \in C_i} \|\vec{x} - \vec{\mu}_i\|_2^2$$

确定聚类数目时,首先使用肘部法则粗略预估相对合理的类簇个数,然后使用轮廓系数度量聚类结果质量,最终在预选的k值中选择轮廓系数最大的k值作为聚类数目。

一种基于语音信号的帕金森患者UPDRS得分预测方法

技术领域

[0001] 本发明涉及帕金森智能诊断领域,具体涉及一种基于语音信号的帕金森患者UPDRS得分预测方法。

背景技术

[0002] 在传统的帕金森患者UPDRS(统一帕金森病评分量表)得分预测中,研究者先后使用最小二乘法、LASSO回归、分类回归树(CART)、C4.5、C5.0、随机森林等算法构建帕金森患者UPDRS得分预测模型。同时为了提高模型的执行效率,使用特征选择方法降低模型输入维度。然而,单一的特征选择方法存在不同程度的不足。例如过滤式方法是先对数据集进行特征选择,然后再训练学习器。该方法依赖于数据集本身,通常是选择和目标函数相关度大的特征或特征子集,一般认为相关度大的特征或特征子集会对应得到后续学习算法较高的准确率。由于过滤式方法独立于具体的学习算法,且只依赖于与数据集本身有关的度量准则,虽具有运行效率高、鲁棒性强等特点,适合处理大规模数据集,但因未考虑到特征间的相互关系,因此过滤式方法得到的特征子集不一定是最优的。而包裹式特征选择方法,其直接把最终将要使用的学习器性能作为特征子集的评价准则,换言之,包裹式特征选择的目的是为给学习器选择最有利于其性能、量身定制的特征子集。虽然包裹式特征选择方法通常可以取得比过滤式方法更高的准确率,但因每个特征子集的评价都要运行相应的学习算法,计算复杂度将明显增大,造成包裹式方法效率较低,不适合处理大规模数据。此外,包裹式方法还依赖于具体的学习算法,因此鲁棒性较差。对于嵌入式特征选择方法,它与前两种特征选择方法均不同,嵌入式特征选择是将特征选择过程与学习器训练过程融为一体,两者在同一个优化过程中完成,即在学习器训练过程中自动进行了特征选择。此外,经典的预测UPDRS得分方法集中在使用所有可用训练数据构建“全局”预测模型。这种“全局”模型忽视了个体差异性,不能较好的捕获数据的细节特征。

发明内容

[0003] 本发明要解决的技术问题是提供一种基于语音信号的帕金森患者UPDRS得分预测方法。该方法受集成学习思想启发,将三种特征选择方法采用绝对多数投票法的结合策略进行集成,解决了传统单一的特征选择方法存在的不同程度的不足;采用k-means聚类方法将相似的患者聚集在一起,利用相似个体预测帕金森患者UPDRS得分,构建个性化预测模型,为每个患者定制UPDRS预测方案,克服了经典“全局”预测模型的不足,提高了UPDRS预测准确度。

[0004] 本发明为解决其技术问题所采用的技术方案为:一种基于语音信号的帕金森患者UPDRS得分预测方法,包括以下步骤:

[0005] 步骤1:基于大量的语音信号特征数据,分别使用过滤式、包裹式、嵌入式三种特征选择方法选择语音信号特征,获得三组特征子集;

[0006] 步骤2:采用绝对多数投票的方式将基于步骤1得到的三组特征子集进行集成,选

择集成后的特征子集作为最终的特征子集；

[0007] 步骤3:将基于步骤2得到的最终的特征子集作为聚类算法k-means的输入,将相似的帕金森患者聚在一起,并利用肘部法则及轮廓系数确定聚类的数目；

[0008] 步骤4:基于步骤3,根据待预测帕金森患者的特征将其划分到相应的类别中,利用相似患者构建个性化预测模型,根据患者个体特征的不同选择相对应的回归算法预测UPDRS得分。如果该患者的特征可使用简单的线性组合的方法拟合就能达到很好的预测效果,就可以使用简单易理解的最小二乘法;如不能用线性方法进行拟合,则考虑使用多项式方法、树回归等复杂方法进行拟合。

[0009] 进一步地,步骤2结合策略采用的绝对多数投票法的公式为:

$$[0010] \quad H(\vec{x}) = \begin{cases} c_j, & \sum_{i=1}^T h_i^j(\vec{x}) > 0.5 \sum_{k=1}^N \sum_{i=1}^T h_i^k(\vec{x}) \\ \text{reject}, & \text{otherwise.} \end{cases}$$

[0011] 其中 h_i 表示特征选择方法,在每个特征选择方法上的预测输出表示为一个N维向量 $(h_i^1(\vec{x}); h_i^2(\vec{x}); \dots; h_i^N(\vec{x}))$;特征子集集合 $\{c_1, c_2, \dots, c_N\}$,其中 c_j 表示特征标记; $h_i^j(\vec{x})$ 表示 h_i 在特征标记 c_j 上的输出,输出结果为1或0,其中1表示选择对应位置的特征,0表示不选择对应位置的特征。绝对多数投票法的原理是某标记得票过半数,则预测为该标记,否则拒绝预测。

[0012] 进一步地,将基于步骤2得到的集成特征选择方法选择出的最终的特征子集 $\{c_1, c_2, \dots, c_N\}$ 作为k-means算法的输入,根据欧氏距离将相似的患者聚集在一起,公式如下:

$$[0013] \quad \arg \min \sum_{i=1}^k \sum_{\vec{x} \in C_i} \|\vec{x} - \vec{\mu}_i\|_2^2$$

[0014] 确定聚类数目时,本发明首先使用肘部法则粗略预估相对合理的类簇个数,然后使用轮廓系数度量聚类结果质量,最终在预选的k值中选择轮廓系数最大的k值作为聚类数目。

[0015] 通过绝对多数投票法将传统的三种特征选择方法(包裹式、嵌入式和过滤式)集成,然后利用集成特征选择方法获得的特征子集作为聚类算法k-means的输入,这一方面提高了算法的执行效率,另一方面也提高了特征选择的鲁棒性。接着在相似患者的基础上建立个性化预测模型,最后根据个体特征的不同选择对应的回归算法个性化预测UPDRS,克服了经典“全局”预测模型的不足,提高了UPDRS预测准确度。

附图说明

[0016] 下面结合附图和具体的实施方式对本发明作进一步详细的说明。

[0017] 图1是本发明一种基于语音信号的个性化预测帕金森患者UPDRS得分预测方法的流程图。

[0018] 图2是本发明方法在UCI machine learning archive进行实验得到的对比堆积条形图。

具体实施方式

[0019] 为使本发明的目的、技术方案和优点更加清楚,下面结合附图和具体实施方式对本发明进行详细描述。

[0020] 图1为本发明的流程图。为实现本发明的基于语音信号的帕金森患者UPDRS得分个性化预测的目的,包括以下步骤:

[0021] 步骤1:基于大量的语音信号特征数据,分别使用过滤式、包裹式、嵌入式三种特征选择方法选择语音信号特征,获得三组特征子集;

[0022] 步骤2:采用绝对多数投票的方式将基于步骤1得到的三组特征子集进行集成,选择集成后的特征子集作为最终的特征子集;

[0023] 步骤3:将基于步骤2得到的最终的特征子集作为聚类算法k-means的输入,将相似的帕金森患者聚在一起,并利用肘部法则及轮廓系数确定聚类的数目;

[0024] 步骤4:基于步骤3,根据待预测帕金森患者的特征将其划分到相应的类别中,利用相似患者构建个性化预测模型,根据患者个体特征的不同选择相对应的回归算法预测UPDRS得分。

[0025] 其中步骤1和2包括以下具体步骤:

[0026] (1) 对于样本数目为S,每个样本含有N个特征的语音信号 $\{f_1, f_2, \dots, f_N\}$:

[0027] 采用过滤式特征选择方法是通过计算每个特征的方差进行,特征的方差小,意味着该特征的识别能力差,直接将其过滤。计算方法如下:

$$[0028] \quad \mu = \frac{f_1^1 + f_1^2 + \dots + f_1^S}{S}$$

$$[0029] \quad \sigma^2 = \frac{\sum_{i=1}^S (f_1^i - \mu)^2}{S}$$

[0030] 其中 f_1^i 表示特征 f_1 在各个样本上的取值; μ 表示特征 f_1 的平均值; σ^2 表示特征 f_1 的方差。使用上述两个公式依次计算出N个特征信号的方差 $\{\sigma_1^2, \sigma_2^2, \dots, \sigma_N^2\}$,将方差小于阈值 θ 的属性过滤,得到过滤式特征选择方法选择的特征信号为 $\{f_1^f, f_2^f, \dots, f_{nf}^f\}$;

[0031] 采用包裹式特征选择方法直接对特定的学习器(逻辑回归、LASSO回归、分类回归树)直接进行迭代优化。迭代过程具体为:首先随机产生特征子集F;接着学习器在特定子集F上使用交叉验证法进行学习,通过学习结果评估学习器的误差err;然后将该误差err与初始化时最优特征子集获得的误差err0进行比较:如果err比err0更小,且F比初始化时选的最优特征子集数量更小,则将F作为最优特征子集,否则继续迭代。最终,得到包裹式特征选择方法选择的特征信号为 $\{f_1^w, f_2^w, \dots, f_{mw}^w\}$;

[0032] 采用嵌入式特征选择方法的L1正则进行特征选择,具体优化目标为:

$$[0033] \quad \arg \min \sum_{i=1}^S (y_i - \vec{w}^T \vec{x}_i)^2 + \lambda \|\vec{w}\|_1, \lambda > 0$$

[0034] 其中 y_i 表示帕金森患者UPDRS实际值; λ 是惩罚系数。优化的具体求解方法使用梯度下降法。通过优化,求得嵌入式特征选择方法的选择的特征信号为 $\{f_1^e, f_2^e, \dots, f_{ne}^e\}$ 。

[0035] (2) 采用绝对多数投票的结合策略对(1)中获得的语音信号特征集成,最终获得特

征子集为 $\{f_1^v, f_2^v, \dots, f_m^v\}$ 。结合策略采用的绝对多数投票法:

$$[0036] \quad H(\vec{x}) = \begin{cases} c_j, & \sum_{i=1}^T h_i^j(\vec{x}) > 0.5 \sum_{k=1}^N \sum_{i=1}^T h_i^k(\vec{x}) \\ \text{reject}, & \text{otherwise.} \end{cases}$$

[0037] 其中 h_i 表示特征选择方法,在每个特征选择方法上的预测输出表示为一个N维向量 $(h_i^1(\vec{x}); h_i^2(\vec{x}); \dots; h_i^N(\vec{x}))$;特征子集集合 $\{c_1, c_2, \dots, c_N\}$,其中 c_j 表示特征标记; $h_i^j(\vec{x})$ 表示 h_i 在特征标记 c_j 上的输出,输出结果为1或0,其中1表示选择对应位置的特征,0表示不选择对应位置的特征。绝对多数投票法的原理是某标记得票过半数,则预测为该标记,否则拒绝预测。

[0038] 其中步骤3和4包括以下具体步骤:

[0039] (3) 将最终的特征子集 $\{f_1^v, f_2^v, \dots, f_m^v\}$ 作为聚类算法k-means的输入,减少聚类算法输入维度,提高算法执行效率;

[0040] (4) 针对聚类所得的簇划分 $C = \{C_1, C_2, \dots, C_k\}$ 最小化平方误差:

$$[0041] \quad E = \sum_{i=1}^k \sum_{x \in C_i} \|\vec{x} - \vec{v}_i\|_2^2$$

[0042] 其中, $\vec{v}_i = \frac{1}{|C_i|} \sum_{x \in C_i} \vec{x}$ 是簇 C_i 的均值向量;

[0043] (5) 在确定聚类数目时,首先借助工程中的肘部法则粗略预估相对合理的类簇个数,然后使用轮廓系数度量聚类结果质量,进一步在预选的k值中选择轮廓系数最大的k值作为聚类数目。

[0044] 由于k-means模型最终期望所有数据点到其所属的类簇距离的平方和趋于稳定,所以可以通过观察该数值随着k的走势找出最佳的类簇数量。理想条件下,这个折线在不断下降并且趋于平缓的过程中会有斜率的拐点,同时也意味着从这个拐点对应的k值开始,类簇中心的增加不会过于破坏数据聚类的结构,这也暗示着此时的k值是相对最佳的类簇数量。为了更好的确定k的数目,使用轮廓系数进一步度量聚类质量,最终选择轮廓系数最大的k值作为最终的帕金森患者聚类数目。大致确定k的范围,进一步通过轮廓系数度量聚类结果的质量,计算方法如下:

$$[0045] \quad sc^i = \frac{b^i - a^i}{\max(b^i, a^i)}$$

[0046] 其中 a^i 表示对于已聚类数据中第i个样本 x^i 与其同一个类簇内的所有其他样本距离的平均值,用于量化簇内的凝簇度; b^i 是通过计算 x^i 与 x^i 外的一个簇b中所有样本的平均距离,遍历所有其他簇,最近的平均距离即为 b^i ,用于量化簇之间分离度; sc^i 的取值范围为 $[-1, 1]$,若 sc^i 小于0,说明 x^i 与其他簇内元素的平均距离大于最近的其他簇,表示聚类效果不好,反之则说明聚类效果较好;

[0047] (6) 通过k-means将相似的帕金森患者聚类后,当需要预测一个帕金森患者的UPDRS得分时,首先将该患者划分到相应的类别,然后使用与该患者相似的患者群体进行建模。根据患者个体特征不同选择相对应的回归算法预测UPDRS得分。如果该患者的特征可使用简单的线性组合的方法拟合就能达到很好的预测效果,就可以使用简单易理解的最小二

乘法;如不能用线性方法进行拟合,则考虑使用多项式方法、树回归等复杂方法进行拟合,从而更有针对性的提高UPDRS的预测精度。

[0048] 本发明具体实施上采用的实验数据是由Athanasios Tsanas和Max Little公开在UCI archive的远程监控的帕金森患者的语音数据集。该数据集包含42名早期的帕金森患者的5875条语音数据,其中男性患者28名,女性患者14名,每名患者的语音数据大约200条。

[0049] 本发明实验的具体实施过程如下:

[0050] 步骤1:获取UCI archive上的5875条帕金森患者语音数据将其按8:1:1划分为训练集、验证集和测试集。

[0051] 对训练集进行过滤式特征提取方法如下:分别计算特征age,sex,Jitter(%),Jitter(Abs),Jitter:RAP,Jitter:PPQ5,Jitter:DDP,Shimmer,Shimmer(dB),Shimmer:APQ3,Shimmer:APQ5,Shimmer:APQ11,Shimmer:DDA,NHR,HNR,RPDE,DFA,PPE的均值、方差,过滤方差小于阈值(设置的阈值保证能留下8个左右的特征)的特征,剩余的特征为:{age,DFA,sex,Jitter(Abs),HNR,NHR,PPE,RPDE};

[0052] 对训练集进行包裹式特征提取,直接调用python机器学习库scikit-learn中的树模型对特征重要性进行排序。为了减少后续算法输入维度,选择特征重要性大于阈值的特征,即{age,sex,Shimmer,Shimmer(dB),Shimmer:APQ5,Shimmer:APQ11,HNR,DFA};

[0053] 对训练集进行嵌入式特征提取使用L1正则,使用python编程知道LASSO算法的稀疏解为{age,sex,Jitter(Abs),Shimmer,NHR,HNR,DFA,PPE},即为嵌入式特征选择获得的特征子集。

[0054] 步骤2:采用绝对多数投票的结合策略对步骤1获得的语音信号特征子集进行集成,可知:

[0055] age→{1,1,1}>1.5接受;

[0056] sex→{1,1,1}>1.5接受;

[0057] DFA→{1,1,1}>1.5接受;

[0058] Jitter(Abs)→{1,0,1}>1.5接受;

[0059] HNR→{1,1,1}>1.5接受;

[0060] NHR→{1,0,1}>1.5接受;

[0061] PPE→{1,0,1}>1.5接受;

[0062] RPDE→{1,0,0}<1.5拒绝;

[0063] Shimmer→{0,1,1}>接受;

[0064] ...

[0065] 最终获得特征子集为{age,sex,Jitter(Abs),Shimmer,DFA,HNR,NHR,PPE};

[0066] 步骤3:将步骤2获得的特征子集{age,sex,Jitter(Abs),Shimmer,DFA,HNR,NHR,PPE}作为k-means算法的输入,这一方面提高特征选择的鲁棒性,另一方面有利于提高算法的执行效率。其中k-means算法中的k通过肘部法则观察及轮廓系数计算确定,最终确定k为3,结果cluster1中的患者编号为:2,3,6,10,12,14,15,16,17,18,22,23,24,27,33,34,20,36,37,38,39,42;cluster2中患者编号为:1,4,5,7,8,9,13,21,25,28,29,31,35,40,41;cluster3中患者编号为:11,19,26,30,32,37。

[0067] 步骤4:使用验证集上的数据进行交叉验证调参,测试集上的数据对本发明的个性

化预测模型进行评估。分别在cluster1,cluster2和cluster3上使用经典的回归算法(LR、LASSO、CART)预测UPDRS得分。

[0068] 进而,使用回归算法中常用评价指标MAE,MSE,R-Squared对预测结果进行评价。发现在三个类别cluster1,cluster2及cluster3中,本发明中的个性化预测方法同传统的方法相比,都取得了较大幅度的提高,尤其是在CART算法上,取得的效果尤为显著。

[0069] 如图2所示,传统方法与个性化预测方法在LR、LASSO、CART上得到的MAE的堆积柱形图表明本发明中的个性化预测方法在基于帕金森患者语音信号预测UPDRS得分中具有较大的优势。其中MAE表示算法预测的UPDRS与实际的UPDRS差的绝对值,MAE的得分越低,效果越好。

[0070] 根据以上步骤,本发明提出了对语音信号特征进行集成特征选择,然后将集成特征选择方法选出的特征子集作为k-means的输入,最后利用相似患者构建个性化预测模型。可以看出,本发明提出集成特征选择方法一方面提高了特征选择的鲁棒性,另一方面避免使用大量的语音特征,提高了算法执行效率。此外,通过构建的个性化预测模型较大幅度的提高了UPDRS的预测准确率,在CART算法上最好的MAE的取值motor_UPDRS达到了2.21,total_UPDRS达到了2.66。

[0071] 综上所述,本发明提出的基于语音信号的帕金森患者UPDRS得分预测方法具有很好的效果且具有较好的鲁棒性。首先集成特征选择方法选出的特征具有较好的代表性,并且在一定程度上提高了特征选择的鲁棒性。其次,本发明根据患者的个体特征,采用聚类的方法将相似的患者聚在一起,在相似个体基础上构建个性化预测模型,克服了经典“全局”预测模型的不足,提高了UPDRS预测准确度。

[0072] 以上所述,仅为本发明较佳的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明披露的技术范围内,根据本发明的技术方案及其发明构思加以等同替换或改变,都应涵盖在本发明的保护范围内。




图1




图2